1 Premières classifications

Le but de ce notebook est de faire des premières classifications. Pour cela nous utilisons le jeu de données IRIS qui est très connu dans la communauté.

Dans un premier temps, nous présentons une première classification pour apprendre à utiliser un classifieur et à prédire une valeur. Les jeux de données d'apprentissage et de de test sont présentés par la suite. Nous présentons ensuite différentes mesures pour évaluer un modèle.
Etant donné qu'il n'est pas possible d'avoir un classifieur universel (NO FREE LUNCH THEOREM), nous verrons comment utiliser différents classifieurs et comment rechercher les meilleurs paramètres d'un classifieur. Enfin nous verrons comment sauvegarder et ré-utiliser un modèle appris.

In [1]:

```
#Sickit learn met régulièrement à jour des versions et
#indique des futurs warnings.
#ces deux lignes permettent de ne pas les afficher.
import warnings
warnings.filterwarnings("ignore", category=FutureWarning)
```

1.1 Le jeu de données IRIS

Nous considérons par la suite le jeu de données des IRIS

In [2]:

```
import pandas as pd
import numpy as np
#https://archive.ics.uci.edu/ml/machine-learning-databases
url="https://archive.ics.uci.edu/ml/machine-learning-databa
names = ['SepalLengthCm', 'SepalWidthCm',
         'PetalLengthCm', 'PetalWidthCm',
         'Species']

df = pd.read_csv(url, names=names)
# 5 premières lignes du fichier
display(df.head())
```

	SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm	Spec
0	5.1	3.5	1.4	0.2	set
1	4.9	3.0	1.4	0.2	set
2	4.7	3.2	1.3	0.2	set
3	4.6	3.1	1.5	0.2	set
4	5.0	3.6	1.4	0.2	set

1.2 Toute première classification

La classification supervisée considère les données sous la forme (X X
,Y Y
) où X X
correspond aux variables prédictives et Y Y
le résultat d'une observation, i.e. la variable à prédire. En se basant sur un jeu d'apprentissage, un algorithme de classification supervisée cherche une fonction mathématique F F
qui permet de transformer (au mieux) X X
vers Y Y
, i.e. $F(X) \approx Y$ $F(X) \approx Y$
.

Convention : les variables prédictives sont celles associées aux objets, généralement stockées sous la forme d'une matrice aussi, par convention, elles sont souvent notées en majuscule (notation d'une matrice). Les variables à prédire sont généralement stockées dans un vecteur et sont souvent notées avec une lettre majuscle (notation d'un vecteur).

Autrement il est tout à fait possible d'utiliser des noms de variables significatives comme data, target.

In [3]:

```
array = df.values #necessité de convertir le dataframe en
#X matrice - utilisation du X majuscule
X = array[:,0:4]
#y vecteur - utilisation du y minuscule
y = array[:,4]

```

Dans scikit-learn, pour apprendre un modèle, un estimateur est créé en appelant sa méthode *fit(X, y)*.
Dans l'exemple qui suit nous utilisons un classifieur naïve Bayes (https://scikit-learn.org/stable/modules/naive_bayes.html) (https://scikit-learn.org/stable/modules/naive_bayes.html)).

In [4]:

```
import sklearn
from sklearn.naive_bayes import GaussianNB

clf = GaussianNB()

clf.fit(X, y)
# la ligne affichée dans le Out indique les hyperparamètre
#du classifieur s'ils existent
```

Out[4]:

```
GaussianNB(priors=None, var_smoothing=1e-09)
```

La ligne affichée dans le Out indique les hyperparamètres du classifieur s'ils existent. Il est également possible de les obtenir à l'aide de :

In [5]:

```
clf.get_params()
```

Out[5]:

```
{'priors': None, 'var_smoothing': 1e-09}
```

Il est alors possible de prédire une valeur non lue à l'aide de la méthode *predict*. Par exemple, nous savons que les valeurs du 5ième IRIS sont 5.0, 3.6, 1.4, 0.2 et qu'il appartient à la classe Iris-setosa.

In [6]:

```
#Prediction du résultat
result = clf.predict([[ 5.0,  3.6,  1.4,  0.2]])
print ('La prédiction du modèle pour [ 5.0,  3.6,  1.4,  0
       result)
```

```
La prédiction du modèle pour [ 5.0,  3.6,  1.4,  0.2
] est ['Iris-setosa']
```

Test de la prédiction sur les données d'apprentissage.

In [7]:

```
result = clf.predict(X)
print (result)
```

```
['Iris-setosa' 'Iris-setosa' 'Iris-setosa' 'Iris-set
osa' 'Iris-setosa'
 'Iris-setosa' 'Iris-setosa' 'Iris-setosa' 'Iris-set
osa' 'Iris-setosa'
 'Iris-setosa' 'Iris-setosa' 'Iris-setosa' 'Iris-set
osa' 'Iris-setosa'
 'Iris-setosa' 'Iris-setosa' 'Iris-setosa' 'Iris-set
osa' 'Iris-setosa'
 'Iris-setosa' 'Iris-setosa' 'Iris-setosa' 'Iris-set
osa' 'Iris-setosa'
 'Iris-setosa' 'Iris-setosa' 'Iris-setosa' 'Iris-set
osa' 'Iris-setosa'
 'Iris-setosa' 'Iris-setosa' 'Iris-setosa' 'Iris-set
osa' 'Iris-setosa'
 'Iris-setosa' 'Iris-setosa' 'Iris-setosa' 'Iris-set
osa' 'Iris-setosa'
 'Iris-setosa' 'Iris-setosa' 'Iris-setosa' 'Iris-set
osa' 'Iris-setosa'
 'Iris-setosa' 'Iris-setosa' 'Iris-setosa' 'Iris-set
osa' 'Iris-setosa'
 'Iris-versicolor' 'Iris-versicolor' 'Iris-virginica
' 'Iris-versicolor'
 'Iris-versicolor' 'Iris-versicolor' 'Iris-versicolo
r' 'Iris-versicolor'
 'Iris-versicolor' 'Iris-versicolor' 'Iris-versicolo
r' 'Iris-versicolor'
 'Iris-versicolor' 'Iris-versicolor' 'Iris-versicolo
r' 'Iris-versicolor'
 'Iris-versicolor' 'Iris-versicolor' 'Iris-versicolo
r' 'Iris-versicolor'
 'Iris-virginica' 'Iris-versicolor' 'Iris-versicolor
' 'Iris-versicolor'
 'Iris-versicolor' 'Iris-versicolor' 'Iris-versicolo
r' 'Iris-virginica'
 'Iris-versicolor' 'Iris-versicolor' 'Iris-versicolo
r' 'Iris-versicolor'
 'Iris-versicolor' 'Iris-versicolor' 'Iris-versicolo
r' 'Iris-versicolor'
 'Iris-versicolor' 'Iris-versicolor' 'Iris-versicolo
r' 'Iris-versicolor'
 'Iris-versicolor' 'Iris-versicolor' 'Iris-versicolo
r' 'Iris-versicolor'
 'Iris-versicolor' 'Iris-versicolor' 'Iris-versicolo
r' 'Iris-versicolor'
 'Iris-versicolor' 'Iris-versicolor' 'Iris-virginica
' 'Iris-virginica'
```

```
 'Iris-virginica' 'Iris-virginica' 'Iris-virginica'
'Iris-virginica'
 'Iris-versicolor' 'Iris-virginica' 'Iris-virginica'
'Iris-virginica'
 'Iris-virginica' 'Iris-virginica' 'Iris-virginica'
'Iris-virginica'
 'Iris-virginica' 'Iris-virginica' 'Iris-virginica'
'Iris-virginica'
 'Iris-virginica' 'Iris-versicolor' 'Iris-virginica'
'Iris-virginica'
 'Iris-virginica' 'Iris-virginica' 'Iris-virginica'
'Iris-virginica'
 'Iris-virginica' 'Iris-virginica' 'Iris-virginica'
'Iris-virginica'
 'Iris-virginica' 'Iris-virginica' 'Iris-virginica'
'Iris-versicolor'
 'Iris-virginica' 'Iris-virginica' 'Iris-virginica'
'Iris-virginica'
 'Iris-virginica' 'Iris-virginica' 'Iris-virginica'
'Iris-virginica'
 'Iris-virginica' 'Iris-virginica' 'Iris-virginica'
'Iris-virginica'
 'Iris-virginica' 'Iris-virginica' 'Iris-virginica'
'Iris-virginica'
```

Une première évaluation de la qualité de la prédiction peut se faire avec le calcul de l'*accuracy* (pourcentage de prédictions correctes).

In [8]:

```
from sklearn.metrics import accuracy_score


print ('accuracy: ',accuracy_score(result, y))

```

```
accuracy:  0.96
```

Comme nous pouvons le constater, même sur le jeu d'apprentissage il y a des erreurs dans le modèle appris. Pour connaître les objets mal classés :

In [9]:

```
y = np.asarray(y)
#misclassified = np.where(y_test != clf.predict(X_test))
misclassified = np.where(y != clf.predict(X))


print('Les objets mal classés sont :')

i=0
for i in misclassified:
    #print('\n','o',i," ",df.iloc[i,:]," ",y[i])
    print('\n',df.iloc[i,:]['Species'])
    #print('\n',df.iloc[i,:]," ",y[i])
    print ('\n')

for i in misclassified:
    print ('\n', i,'classé en ',clf.predict(X)[i],'\n')
    print ('\n')
```

```
Les objets mal classés sont :

 52     Iris-versicolor
70     Iris-versicolor
77     Iris-versicolor
106     Iris-virginica
119     Iris-virginica
133     Iris-virginica
Name: Species, dtype: object



 [ 52  70  77 106 119 133] classé en  ['Iris-virgini
ca' 'Iris-virginica' 'Iris-virginica' 'Iris-versicol
or'
 'Iris-versicolor' 'Iris-versicolor']
```

1.3 Jeu d'apprentissage et de test

In [10]:

```
import pandas as pd
#https://archive.ics.uci.edu/ml/machine-learning-databases
url="https://archive.ics.uci.edu/ml/machine-learning-databa
names = ['SepalLengthCm', 'SepalWidthCm',
         'PetalLengthCm', 'PetalWidthCm',
         'Species']

df = pd.read_csv(url, names=names)

array = df.values
X = array[:,0:4]
y = array[:,4]

```

En classification, il est indispensable de créer un jeu d'apprentissage sur lequel un modèle est appris et un jeu de test pour évaluer le modèle. La fonction *train_test_split* permet de décomposer le jeu de données en 2 groupes : les données pour l'apprentissage et les données pour les tests.

Le paramètre *train_size* indique la taille du jeu d'apprentissage qui sera utilisé.
le paramètre *random_state* spécifie un entier germe du nombre aléatoire pour le tirage. S'il n'est pas spécifié sickit learn utilise un générateur de nombre aléatoire à partir de np.random.

Depuis la version 0.21 il est également nécessaire de préciser la taille du jeu de test_size. De manière classique ce nombre est égal à la différence entre la taille du jeu de données - le test_size (1-test_size). Via cette fonctionnalité sickit learn permet de faire de l'échantillonage sur le jeu d'apprentissage.

Dans notre exemple nous prenons 30% du jeu de données comme jeu de test.

In [11]:

```
from sklearn.model_selection import train_test_split

validation_size=0.3 #30% du jeu de données pour le test

testsize= 1-validation_size
seed=30
X_train,X_test,y_train,y_test=train_test_split(X,
                                               y,
                                               train_size=v
                                               random_state
                                               test_size=te

```

L'apprentissage du modèle se fait comme précédemment

In [12]:

```
clf = GaussianNB()
clf.fit(X_train, y_train)

```

Out[12]:

```
GaussianNB(priors=None, var_smoothing=1e-09)
```

De même pour la prédiction

In [13]:

```
from sklearn.metrics import accuracy_score

result = clf.predict(X_test)
print('\n accuracy :', accuracy_score(result, y_test),'\n'

```

```
 accuracy : 0.9428571428571428
```

Le problème essentiel de cette approche est que le modèle est appris sur un seul jeu de données et qu'en fonction de la sélection les résultats peuvent être très différents. La bonne solution consiste à utiliser la **cross validation**. Dans notre cas, nous allons utiliser une 10-fold cross validation pour évaluer la qualité. Le jeu de données sera découpé en 10 partie, entrainé sur 9, testé sur 1 et cela sera répété pour toutes les combinaisons du découpage.

In [14]:

```
from sklearn.model_selection import KFold
from sklearn.model_selection import cross_val_score
seed=7
k_fold = KFold(n_splits=10, shuffle=True, random_state=seed
```

In [15]:

```
clf = GaussianNB()

scoring = 'accuracy'
score = cross_val_score(clf, X, y, cv=k_fold, scoring=scor

print('Les différentes accuracy pour les 10 évaluations so
      score,'\n')
print ('Accuracy moyenne : ',score.mean(),
       ' standard deviation', score.std())

```

```
Les différentes accuracy pour les 10 évaluations son
t :
 [0.8        0.86666667 1.         1.         0.9333
3333 1.
 1.         1.         0.93333333 1.        ]

Accuracy moyenne :  0.9533333333333334  standard dev
iation 0.06699917080747259
```

L'écart type (standard deviation) est très important car il montre les grandes variations qui peuvent exister par rapport aux jeux de données.

1.4 Plus loin sur l'évaluation d'un modèle

L'accuracy (nombre d'objets correctement classés) est la métrique la plus simple pour comprendre le résultat de la classification mais ne tient pas du tout compte de la distribution des données et ne permet pas d'indiquer les erreurs. Par exemple avec des classes très déséquilibrées (1 vs 99), nous pouvons avoir un modèle avec une accuracy de 99% mais lorsque qu'un objet de la classe intervient nous ne pouvons pas le retrouver.

Par la suite, par simplification, nous reprenons une classification réalisée sans cross validation mais le principe est évidemment le même avec cross validation. Nous introduisons la matrice de correlation et les différentes mesures : precision, rappel et F1-score.

In [16]:

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
url="https://archive.ics.uci.edu/ml/machine-learning-databa
names = ['SepalLengthCm', 'SepalWidthCm',
         'PetalLengthCm', 'PetalWidthCm', 'Species']
df = pd.read_csv(url, names=names)
array = df.values
X = array[:,0:4]
y = array[:,4]

validation_size=0.3 #30% du jeu de données pour le test

testsize= 1-validation_size
seed=30
X_train,X_test,y_train,y_test=train_test_split(X, y,
                                               train_size=
                                               random_state
                                               test_size=te
clf = GaussianNB()
clf.fit(X_train, y_train)
result = clf.predict(X_test)

print('\n accuracy:',accuracy_score(result, y_test),'\n')
```

```
accuracy: 0.9428571428571428
```

La matrice de confusion permet de connaître les objets bien ou mal classés. Il suffit d'utiliser la fonction *confusion_matrix*.

In [17]:

```
from sklearn.metrics import confusion_matrix

conf = confusion_matrix(y_test, result)
print ('\n matrice de confusion \n',conf)

```

```
 matrice de confusion
 [[34  0  0]
 [ 0 33  5]
 [ 0  1 32]]
```

Il est possible d'obtenir plus d'information : *precision*, *recall* et *f1-measure* à l'aide de *classification_report*.

In [18]:

```
from sklearn.metrics import classification_report
conf = confusion_matrix(y_test, result)
print ('\n matrice de confusion \n',conf)
print ('\n',classification_report(y_test, result))
```

```
 matrice de confusion
 [[34  0  0]
 [ 0 33  5]
 [ 0  1 32]]

                precision    recall  f1-score   su
pport

    Iris-setosa       1.00      1.00      1.00
34
Iris-versicolor       0.97      0.87      0.92
38
 Iris-virginica       0.86      0.97      0.91
33

      micro avg       0.94      0.94      0.94
105
      macro avg       0.95      0.95      0.94
105
   weighted avg       0.95      0.94      0.94
105
```

Rappel :

Considérons une matrice de confusion dans un cas binaire. Par exemple présence de SPAM ou non dans des mails.

$N = 115$	**PREDIT NON**	**PREDIT OUI**
REEL NON	60	10
REEL OUI	5	40

$N = 115$	**PREDIT NON**	**PREDIT OUI**
REEL NON	60	10
REEL OUI	5	40

La matrice nous permet de voir qu'il y a deux classes prédites (OUI ou NON). Le classifieur fait un total de 115 prédictions. Sur ces 115 cas, le classifieur a prédit OUI 50 fois et NON 65 fois. En fait 45 documents sont des SPAMS et 70 ne le sont pas.

TP (True positive) : il s'agit des objets qui étaient prédits OUI (il s'agit de SPAM) et qui sont effectivement des SPAM.
TN (True negative) : il s'agit des objets qui étaient prédits NON (il ne s'agit pas de SPAM) et qui effectivement ne sont pas des SPAM.
FP (False positive) : il s'agit des objets qui étaient prédits comme SPAM mais qui en fait n'étaient pas des SPAM.
FN (False negative) : il s'agit des objets qui étaient prédits comme non SPAM qui en fait s'avèrent être des SPAM.
Dans la matrice ci-dessous ces éléments sont reportés :

$N = 115$	**PREDIT NON**	**PREDIT OUI**	
REEL NON	$TN = 60$	$FP = 10$	70
REEL OUI	$FN = 5$	$TP = 40$	45
	65	50	

$N =$ 115	**PREDIT NON**	**PREDIT OUI**	
REEL NON	$TN = 60$	$FP = 10$	70
REEL OUI	$FN = 5$	$TP = 40$	45
	65	50	

L'**accuracy** correspond au pourcentage de prédiction correcte. Elle est définie par

$$\frac{TP + TN}{TN + FP + FN + TP} = \frac{40 + 60}{60 + 10 + 5 + 40} = 0.86.$$

$$\frac{TP + TN}{TN + FP + FN + TP} = \frac{40 + 60}{60 + 10 + 5 + 40} = 0.86.$$

Le **recall** (ou sensitivity ou True Positive Rate ou rappel) correspond au nombre d' objets pertinents retrouvés par rapport aux nombres d'objets pertinents du jeu de données. Dans notre cas, pour tous les OUI présents combien de fois le OUI a t'il été prédit ?

$$recall = \frac{Nombre\ de\ SPAM\ correctement\ reconnus}{Nombre\ total\ de\ SPAM\ dans\ le\ jeu\ de\ données} = \frac{TP}{FN + TP} = \frac{40}{40 + 5}$$

$$recall = \frac{Nombre\ de\ SPAM\ correctement\ reconnus}{Nombre\ total\ de\ SPAM\ dans\ le\ jeu\ de\ données} = \frac{TP}{FN + TP} = \frac{40}{40 + 5} = 0.88.$$

La **precision** correspond à la proportion d'objets pertinents parmi les objets sélectionné. Tous les objets retournés non pertinents constituent du bruit.

$$precision = \frac{Nombre\ de\ SPAM\ correctement\ reconnus}{Nombre\ de\ fois\ où\ un\ objet\ a\ été\ prédit\ SPAM} = \frac{TP}{TP + FP} = \frac{4}{40 +$$

$$precision = \frac{Nombre\ de\ SPAM\ correctement\ reconnus}{Nombre\ de\ fois\ où\ un\ objet\ a\ été\ prédit\ SPAM} = \frac{TP}{TP + FP} = \frac{40}{40 + 10} = 0.8.$$

Le **f1-score** (ou f-measure) est la moyenne harmonique du rappel et de la précision.

$$f1 - score = 2 \times \frac{precision \times recall}{precision + recall} = 2 \times \frac{0.8 \times 0.88}{0.8 + 0.88}.$$

$$f1 - score = 2 \times \frac{precision \times recall}{precision + recall} = 2 \times \frac{0.8 \times 0.88}{0.8 + 0.88}.$$

Dans le cas d'une classification multiclasse, à partir de la matrice de confusion, la precision est calculée, pour une colonne ii, par :

$$precision_i = \frac{M_{ii}}{\sum_j M_{ji}}$$

$$precision_i = \frac{M_{ii}}{\sum_j M_{ji}}$$

et le recall par :

$$recall_i = \frac{M_{ii}}{\sum_j M_{ij}}$$

$$recall_i = \frac{M_{ii}}{\sum_j M_{ij}}$$

Pour la matrice de confusion suivante :

$$\begin{array}{lccc} Iris-setosa & 34 & 0 & 0 \\ Iris-versicolor & 0 & 33 & 5 \\ Iris-virginica & 0 & 1 & 32 \end{array}$$

$$\begin{array}{lccc} Iris-setosa & 34 & 0 & 0 \\ Iris-versicolor & 0 & 33 & 5 \\ Iris-virginica & 0 & 1 & 32 \end{array}$$

classification_report retourne le résultat suivant :

$$\begin{array}{lcccc} & precision & recall & f1-score & support \\ \\ Iris-setosa & 1.00 & 1.00 & 1.00 & 34 \\ Iris-versicolor & 0.97 & 0.87 & 0.92 & 38 \\ Iris-virginica & 0.86 & 0.97 & 0.91 & 33 \\ \\ avg/total & 0.95 & 0.94 & 0.94 & 105 \end{array}$$

$$\begin{array}{lcccc} & precision & recall & f1-score & support \\ Iris-setosa & 1.00 & 1.00 & 1.00 & 34 \\ Iris-versicolor & 0.97 & 0.87 & 0.92 & 38 \\ Iris-virginica & 0.86 & 0.97 & 0.91 & 33 \\ avg/total & 0.95 & 0.94 & 0.94 & 105 \end{array}$$

La precision d'Iris-versicolor est obtenue par :

$$precision_i = \frac{M_{ii}}{\sum_j M_{ji}} = \frac{33}{33+1} = 0.97.$$

$$precision_i = \frac{M_{ii}}{\sum_j M_{ji}} = \frac{33}{33+1} = 0.97.$$

Le rappel d'Iris-versicolor est obtenue par :

$$recall_i = \frac{M_{ii}}{\sum_j M_{ij}} = \frac{33}{33+5} = 0.87.$$

$$recall_i = \frac{M_{ii}}{\sum_j M_{ij}} = \frac{33}{33+5} = 0.87.$$

La precision d'Iris-virginica est obtenue par :

$$precision_i = \frac{M_{ii}}{\sum_j M_{ji}} = \frac{32}{32+5} = 0.86.$$

$$precision_i = \frac{M_{ii}}{\sum_j M_{ji}} = \frac{32}{32+5} = 0.86.$$

Le rappel d'Iris-versicolor est obtenue par :

$$recall_i = \frac{M_{ii}}{\sum_j M_{ij}} = \frac{32}{32+1} = 0.96.$$

$$recall_i = \frac{M_{ii}}{\sum_j M_{ij}} = \frac{32}{32+1} = 0.96.$$

Pour connaître les objets mal classés :

In [19]:

```
misclassified = np.where(y != clf.predict(X))

print('Les objets mal classés sont :')

i=0
for i in misclassified:
    print('\n',df.iloc[i,:]['Species'])
    print ('\n')

for i in misclassified:
    print ('\n', i,'classé en ',clf.predict(X)[i],'\n')

```

```
Les objets mal classés sont :

 52     Iris-versicolor
56     Iris-versicolor
70     Iris-versicolor
77     Iris-versicolor
83     Iris-versicolor
106     Iris-virginica
119     Iris-virginica
Name: Species, dtype: object



 [ 52  56  70  77  83 106 119] classé en  ['Iris-vir
ginica' 'Iris-virginica' 'Iris-virginica' 'Iris-virg
inica'
 'Iris-virginica' 'Iris-versicolor' 'Iris-versicolor
']
```

Pour afficher, avec seaborn, la matrice de confusion.

In [20]:

```
import seaborn as sns
import matplotlib.pyplot as plt

labels = ['Iris-setosa', 'Iris-versicolor','Iris-virginica
fig, ax = plt.subplots(1, 1, figsize=(10,6))
hm = sns.heatmap(conf,
                 ax=ax,            # Axes où afficher
                 xticklabels=labels, #labels sur les x
                 yticklabels=labels, #labels sur les colon
                 cmap="YlGnBu", # Couleur
                 square=True,    # Si True, toutes les cel
                                 #ont le même aspect carré
                 annot=True      # Pour afficher les valeu
                )
fig.suptitle('GaussianNB\nAccuracy:{0:.3f}'.format(accurac
               fontsize=12,
               fontweight='bold')
plt.show()
```

```
<Figure size 1000x600 with 2 Axes>
```

Les métriques peuvent être appelées indépendamment. Par exemple
from sklearn.metrics import precision_score
print("Precision score: {}".format(precision_score(y_true,y_pred)))
ou à l'aide de la fonction *precision_recall_fscore_support*

In [21]:

```
from sklearn.metrics import precision_recall_fscore_suppor

precision, recall, fscore, support = score(y_test, result)

print('precision: {}'.format(precision))
print('recall: {}'.format(recall))
print('fscore: {}'.format(fscore))
print('support: {}'.format(support))
```

```
precision: [1.         0.97058824 0.86486486]
recall: [1.         0.86842105 0.96969697]
fscore: [1.         0.91666667 0.91428571]
support: [34 38 33]
```

Remarque : il existe, bien entendu, d'autres mesures pour évaluer un classifieur. Par exemple, la sensiblité, la spécificité, l'air sous la courbe roc (AUC), l'indice de Gini (voir cours).

1.5 Utiliser plusieurs classifiers

Comme l'indique le NO FREE LUNCH THEOREM il n'existe pas un classifieur universel et en fonction des données il est souvent nécessaire d'en évaluer plusieurs pour retenir le plus efficace. Le principe est similaire au précédent, il suffit de les mettre dans une structure et de boucler dessus.

In [22]:

```
#preparation des données
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
url = "https://archive.ics.uci.edu/ml/machine-learning-data
names = ['SepalLengthCm', 'SepalWidthCm', 'PetalLengthCm',
df = pd.read_csv(url, names=names)
array = df.values
X = array[:,0:4]
y = array[:,4]

validation_size=0.3 #30% du jeu de données pour le test

testsize= 1-validation_size
seed=30
X_train, X_test, y_train, y_test = train_test_split(X, y,
```

Dans l'exemple, nous utilison LogisticRegression, DecisionTree, KNeighbors, GaussianNB et SVM.
Les paramètres utilisés pour chacune des approches sont ceux par défaut. Pour chaque approche nous faisons une cross validation de 10.

In [23]:

```
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn.neighbors import KNeighborsClassifier
from sklearn.naive_bayes import GaussianNB
from sklearn.svm import SVC

seed = 7
scoring = 'accuracy'
models = []
models.append(('LR', LogisticRegression(solver='lbfgs')))
models.append(('KNN', KNeighborsClassifier()))
models.append(('CART', DecisionTreeClassifier()))
models.append(('NB', GaussianNB()))
models.append(('SVM', SVC(gamma='auto')))


```

In [24]:

```
from sklearn.metrics import confusion_matrix
from sklearn.metrics import classification_report
from sklearn.model_selection import KFold
from sklearn.model_selection import cross_val_score
import time
results = []
names = []
for name,model in models:
    kfold = KFold(n_splits=10, random_state=seed)
    start_time = time.time()
    cv_results = cross_val_score(model, X, y, cv=kfold, sc
    #pour avoir les paramètres utilisés dans le modèle enl
    #print (model.get_params())
    print ("Time pour",name," ",time.time() - start_time)
    results.append(cv_results)
    names.append(name)
    msg = "%s: %f (%f)" % (name, cv_results.mean(), cv_resu
    print(msg)
```

```
Time pour LR   0.15139937400817871
LR: 0.900000 (0.116428)
Time pour KNN   0.01901412010192871
KNN: 0.933333 (0.084327)
Time pour CART   0.011366367340087891
CART: 0.946667 (0.065320)
Time pour NB   0.018451929092407227
NB: 0.946667 (0.058119)
Time pour SVM   0.012649774551391602
SVM: 0.953333 (0.052068)
```

In [25]:

```
fig = plt.figure()
fig.suptitle('Comparaison des algorithmes')
ax = fig.add_subplot(111)
plt.boxplot(results)
ax.set_xticklabels(names)
```

Out[25]:

```
[Text(0, 0, 'LR'),
 Text(0, 0, 'KNN'),
 Text(0, 0, 'CART'),
 Text(0, 0, 'NB'),
 Text(0, 0, 'SVM')]
```

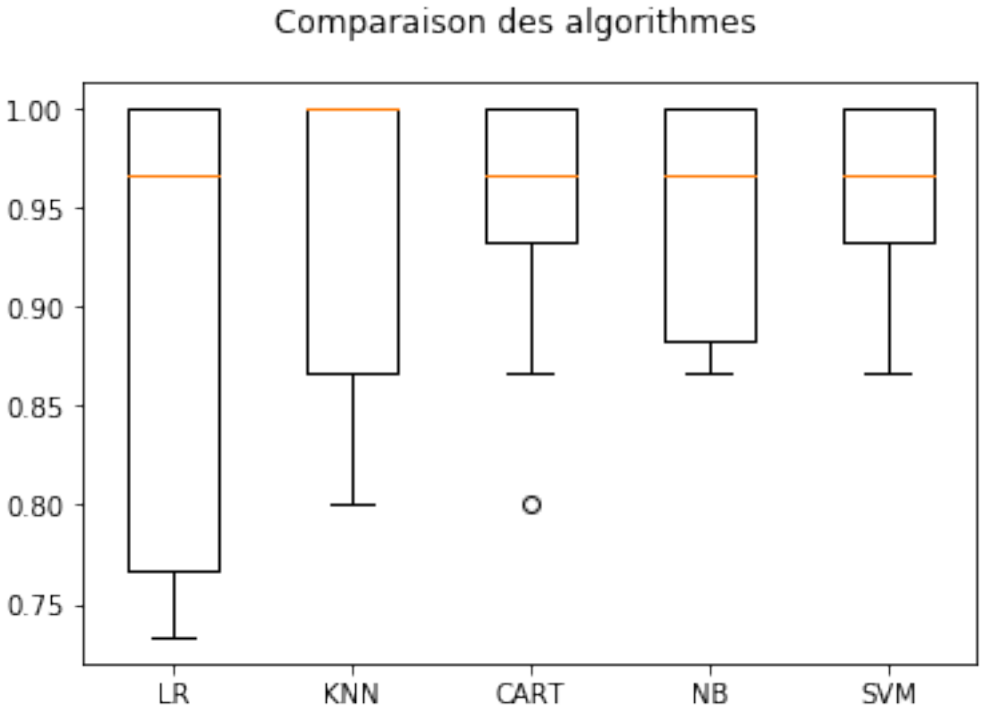

Comme SVM donne des meilleurs résultats, nous pouvons l'utiliser comme modèle de prédiction.

In [26]:

```
from sklearn.metrics import accuracy_score
from sklearn.metrics import confusion_matrix
from sklearn.metrics import classification_report
clf = SVC(gamma='auto')
clf.fit(X_train, y_train)
result = clf.predict(X_test)

print('\n accuracy: ', accuracy_score(result, y_test),'\n'

conf = confusion_matrix(y_test, result)
print ('\n matrice de confusion \n',conf)
print ('\n',classification_report(y_test, result))
```

```
 accuracy:  0.9619047619047619


 matrice de confusion
 [[34  0  0]
 [ 0 34  4]
 [ 0  0 33]]

                precision    recall  f1-score   su
pport

    Iris-setosa       1.00      1.00      1.00
34
Iris-versicolor       1.00      0.89      0.94
38
 Iris-virginica       0.89      1.00      0.94
33

      micro avg       0.96      0.96      0.96
105
      macro avg       0.96      0.96      0.96
105
   weighted avg       0.97      0.96      0.96
105
```

1.6 Les hyperparamètres

Dans l'approche précédente nous avons pris les valeurs par défaut pour les différents classifieurs. Cependant en fonction des paramètres du classifieur les résultats peuvent être complétement différents (choix du noyeau SVM, nombre de K dans KNeighbors, etc.). Sikit learn permet de pouvoir faire une recherche exhaustive (grid search) pour trouver les paramètres les plus pertinents pour un classifieur.

In [27]:

```
#preparation des données
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
url = "https://archive.ics.uci.edu/ml/machine-learning-data
names = ['SepalLengthCm', 'SepalWidthCm', 'PetalLengthCm',
df = pd.read_csv(url, names=names)
array = df.values
X = array[:,0:4]
y = array[:,4]

validation_size=0.3 #30% du jeu de données pour le test

testsize= 1-validation_size
seed=30
X_train, X_test, y_train, y_test = train_test_split(X, y,
                                                    train_s
                                                    random_
                                                    test_si
```

Considérons un arbre de décision. Les principaux paramètres sont le critère pour découper (gini ou entropy), la profondeur maximale de l'arbre, et le nombre d'échantillons par feuille. Il faut, dans un premier temps, initialiser les variables à tester dans un dictionnaire.
Le test de toutes les valeurs se fait à l'aide de la fonction *GridSearchCV*. Ele prend commme paramètre le classifieur, le dictionnaire ds paramètre, le type de scoring, le nombre de crossvalidation.

Quelques paramètres souvent utilisés :

- *n_jobs* : (par défaut 1) nombre de coeurs à utiliser pour effectuer les calculs, dépend du cpu. Si la machine possède plusieurs coeurs, il est possible d'indiquer de tous les utiliser en mettant *n_jobs=-1*
- *verbose* : affichage du déroulement des calculs, 0 = silent.
- *random_state* : si le classifieur utilisé utilise de l'aléatoire, random_state permet de fixer le générateur pour reproduire les résultats.

Un grid search est long à obtenir dans la mesure où il faut essayer l'ensemble des cas. La possibilité de répartir sur plusieurs processeur permet de faire gagner beaucoup de temps.

In [28]:

```
from sklearn.tree import DecisionTreeClassifier
from sklearn.model_selection import GridSearchCV

grid_param = {
    'max_depth': [1,2,3,4,5,6,7,8,9,10],
    'criterion': ['gini', 'entropy'],
    'min_samples_leaf': [1,2,3,4,5,6,7,8,9,10]
}


gd_sr = GridSearchCV(estimator=DecisionTreeClassifier(),
                     param_grid=grid_param,
                     scoring='accuracy',
                     cv=5,
                     n_jobs=-1,
                    iid=True,
                    return_train_score=True)

gd_sr.fit(X_train, y_train)


```

Out[28]:

```
GridSearchCV(cv=5, error_score='raise-deprecating',
       estimator=DecisionTreeClassifier(class_weight
=None, criterion='gini', max_depth=None,
            max_features=None, max_leaf_nodes=None,
            min_impurity_decrease=0.0, min_impurity_
split=None,
            min_samples_leaf=1, min_samples_split=2,
            min_weight_fraction_leaf=0.0, presort=Fa
lse, random_state=None,
            splitter='best'),
       fit_params=None, iid=True, n_jobs=-1,
       param_grid={'max_depth': [1, 2, 3, 4, 5, 6, 7
, 8, 9, 10], 'criterion': ['gini', 'entropy'], 'min_
samples_leaf': [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]},
       pre_dispatch='2*n_jobs', refit=True, return_t
rain_score=True,
       scoring='accuracy', verbose=0)
```

Pour connaître les meilleures conditions :

In [29]:

```
print ('meilleur score ',gd_sr.best_score_,'\n')
print ('meilleurs paramètres', gd_sr.best_params_,'\n')
print ('meilleur estimateur',gd_sr.best_estimator_,'\n')
```

```
meilleur score  0.9777777777777777

meilleurs paramètres {'criterion': 'gini', 'max_dept
h': 2, 'min_samples_leaf': 1}

meilleur estimateur DecisionTreeClassifier(class_wei
ght=None, criterion='gini', max_depth=2,
            max_features=None, max_leaf_nodes=None,
            min_impurity_decrease=0.0, min_impurity_
split=None,
            min_samples_leaf=1, min_samples_split=2,
            min_weight_fraction_leaf=0.0, presort=Fa
lse, random_state=None,
            splitter='best')
```

Avec KNeighborsClassifier()

In [30]:

```
from sklearn.neighbors import KNeighborsClassifier
grid_param = {
    'n_neighbors': list(range(1,15)),
    'metric': ['minkowski','euclidean','manhattan']
}

gd_sr = GridSearchCV(estimator=KNeighborsClassifier(),
                     param_grid=grid_param,
                     scoring='accuracy',
                     cv=5,
                     n_jobs=-1,
                    iid=True,
                    return_train_score=True)

gd_sr.fit(X_train, y_train)

print ('meilleur score ',gd_sr.best_score_,'\n')
print ('meilleurs paramètres', gd_sr.best_params_,'\n')
print ('meilleur estimateur',gd_sr.best_estimator_,'\n')

```

```
meilleur score  1.0

meilleurs paramètres {'metric': 'minkowski', 'n_neig
hbors': 1}

meilleur estimateur KNeighborsClassifier(algorithm='
auto', leaf_size=30, metric='minkowski',
           metric_params=None, n_jobs=None, n_neighb
ors=1, p=2,
           weights='uniform')
```

Avec SVM

In [31]:

```
from sklearn.svm import SVC
grid_param = {
    'C': [0.001, 0.01, 0.1, 1, 10],
    'gamma' : [0.001, 0.01, 0.1, 1],
    'kernel': ['linear','rbf']}

gd_sr = GridSearchCV(estimator=SVC(),
                     param_grid=grid_param,
                     scoring='accuracy',
                     cv=5,
                     n_jobs=1,
                     iid=True,
                    return_train_score=True)

gd_sr.fit(X_train, y_train)

print ('meilleur score ',gd_sr.best_score_,'\n')
print ('meilleurs paramètres', gd_sr.best_params_,'\n')
print ('meilleur estimateur',gd_sr.best_estimator_,'\n')

```

```
meilleur score  1.0

meilleurs paramètres {'C': 1, 'gamma': 0.001, 'kerne
l': 'linear'}

meilleur estimateur SVC(C=1, cache_size=200, class_w
eight=None, coef0=0.0,
  decision_function_shape='ovr', degree=3, gamma=0.0
01, kernel='linear',
  max_iter=-1, probability=False, random_state=None,
shrinking=True,
  tol=0.001, verbose=False)
```

Pour voir l'ensemble des évaluations effectuées par GridSearchCV :

In [32]:

```
# convertion en DataFrame
results = pd.DataFrame(gd_sr.cv_results_)
# Affichage des 5 premières lignes
display(results.head())
```

	mean_fit_time	mean_score_time	mean_test_score	mean_train_score
0	0.000950	0.000479	0.444444	0.452069
1	0.000517	0.000292	0.444444	0.452069
2	0.000436	0.000277	0.444444	0.452069
3	0.000468	0.000308	0.444444	0.452069
4	0.000377	0.000345	0.444444	0.452069

5 rows × 23 columns

L'avantage de GridSearchCV est qu'il va parcourir toutes les conditions et retourner celles qui sont les meilleures pour la ou les mesures de scoring recherchée (dans notre cas nous avons privilégié l'accuracy). Cela est très pratique mais est malheureusement impossible dans certains cas car beaucoup trop long à mettre en place. Une solution possible est d'utiliser *RandomizedSearchCV* qui parcourt de manière aléatoire l'espace de recherche. Il suffit dans ce cas de spécifier des tirages aléatoires pour les valeurs possibles des paramètres et de préciser le nombre d'itérations voulues. Le second usage de *RandomizedSearchCV* est, lorsque l'on n'a pas une très bonne idée de ce que cela peut donner ou des paramètres à utiliser de faire appel à lui pour avoir des valeurs qui peuvent être significatives et de faire suivre à partir de ces valeurs une recherche via *GridSearchCV*.

In [33]:

```
from sklearn.tree import DecisionTreeClassifier
from sklearn.model_selection import RandomizedSearchCV
from scipy.stats import randint

rand_param = {
    'max_depth': randint(1, 20),
    'criterion': ['gini', 'entropy'],
    'min_samples_leaf': randint(1, 20)
}


rand_sr = RandomizedSearchCV(estimator=DecisionTreeClassif
                             param_distributions = rand_pa
                             random_state=1,
                             n_iter=20,
                             cv=3,
                             n_jobs=-1,
                             scoring='accuracy',
                             iid=True,
                             return_train_score=True)

rand_sr.fit(X_train, y_train)

print ('meilleur score ',rand_sr.best_score_,'\n')
print ('meilleurs paramètres', rand_sr.best_params_,'\n')
print ('meilleur estimateur',rand_sr.best_estimator_,'\n')

# convertion en DataFrame
results = pd.DataFrame(rand_sr.cv_results_)
# Affichage des 5 premières lignes
display(results.head())

```

```
32
33
```

```
meilleur score  0.9555555555555556

meilleurs paramètres {'criterion': 'entropy', 'max_d
epth': 16, 'min_samples_leaf': 1}

meilleur estimateur DecisionTreeClassifier(class_wei
ght=None, criterion='entropy', max_depth=16,
            max_features=None, max_leaf_nodes=None,
            min_impurity_decrease=0.0, min_impurity_
split=None,
            min_samples_leaf=1, min_samples_split=2,
            min_weight_fraction_leaf=0.0, presort=Fa
lse, random_state=None,
            splitter='best')
```

	mean_fit_time	mean_score_time	mean_test_score	mean_train_score
0	0.000518	0.000348	0.733333	0.733136
1	0.000512	0.000590	0.733333	0.733136
2	0.000421	0.000315	0.955556	1.000000
3	0.000503	0.000392	0.733333	0.733136
4	0.000288	0.000228	0.955556	1.000000

1.7 Gridsearch et plusieurs classifieurs

Il est tout à fait possible d'utiliser Gridsearch avec plusieurs classifieurs. Il suffit pour cela d'initaliser les classifiers dans un biblitothèse et faire de même pour les paramètres.

In [34]:

```
from sklearn.tree import DecisionTreeClassifier
from sklearn.neighbors import KNeighborsClassifier
from sklearn.svm import SVC

classifiers = {
    'KNeighborsClassifier': KNeighborsClassifier(),
    'DecisionTreeClassifier': DecisionTreeClassifier(),
    'SVC': SVC()
}

params = {'KNeighborsClassifier' : [{'n_neighbors': list(r
    {'metric': ['minkowski','euclidean','manhattan']}],
           'DecisionTreeClassifier': [{'max_depth': [1,2,3
    {'criterion': ['gini', 'entropy']},
    {'min_samples_leaf': [1,2,3,4,5,6,7,8,9,10]}],
       'SVC':[{'C': [0.001, 0.01, 0.1, 1, 10],
    'gamma' : [0.001, 0.01, 0.1, 1],
    'kernel': ['linear','rbf']}]  }
```

In [35]:

```
class Result:
     def __init__(self,name, score, parameters):
         self.name = name
         self.score = score
         self.parameters = parameters
     def __repr__(self):
         return repr((self.name, self.score, self.parameter


results = []
for key,value in classifiers.items():
    gd_sr = GridSearchCV(estimator=value,
                         param_grid=params[key],
                         scoring='accuracy',
                         cv=5,
                         n_jobs=1,
                         iid=True)
```

```
    gd_sr.fit(X_train, y_train)
    result=Result(key,gd_sr.best_score_,gd_sr.best_estimat
    results.append(result)



results=sorted(results, key=lambda result: result.score, re

print ('Le meilleur resultat : \n')
print ('Classifier : ',results[0].name,
       ' score %0.2f' %results[0].score,
       ' avec ',results[0].parameters,'\n')

print ('Tous les résultats : \n')
for result in results:
    print ('Classifier : ',result.name,
           ' score %0.2f' %result.score,
           ' avec ',result.parameters,'\n')


```

```
Le meilleur resultat :

Classifier :  KNeighborsClassifier  score 1.00  avec
KNeighborsClassifier(algorithm='auto', leaf_size=30,
metric='minkowski',
           metric_params=None, n_jobs=None, n_neighb
ors=1, p=2,
           weights='uniform')

Tous les résultats :

Classifier :  KNeighborsClassifier  score 1.00  avec
KNeighborsClassifier(algorithm='auto', leaf_size=30,
metric='minkowski',
           metric_params=None, n_jobs=None, n_neighb
ors=1, p=2,
           weights='uniform')

Classifier :  SVC  score 1.00  avec  SVC(C=1, cache_
size=200, class_weight=None, coef0=0.0,
  decision_function_shape='ovr', degree=3, gamma=0.0
01, kernel='linear',
  max_iter=-1, probability=False, random_state=None,
shrinking=True,
  tol=0.001, verbose=False)

Classifier :  DecisionTreeClassifier  score 0.98  av
```

```
ec  DecisionTreeClassifier(class_weight=None, criter
ion='gini', max_depth=2,
            max_features=None, max_leaf_nodes=None,
            min_impurity_decrease=0.0, min_impurity_
split=None,
            min_samples_leaf=1, min_samples_split=2,
            min_weight_fraction_leaf=0.0, presort=Fa
lse, random_state=None,
            splitter='best')
```

1.8 Les pipelines

Il peut arriver que différentes combinaisons de pré-traitements puissent être utilisées. Par exemple il est possible d'utiliser du changement d'échelle, du PCA (projection sur un nombre différent de dimensions), de faire du remplacement de valeurs manquantes ...

L'objectif du pipeline est de pouvoir regrouper l'ensemble de ces prétraitements et de pouvoir les faire suivre par le classifier. Le principe consiste à d'abord mettre la chaîne de pré-traitement, d'ensuite mettre le classifier et d'utiliser directement le pipeline.

Attention les pipelines sont très importants lorsque l'on sauvegarde un modèle. En effet comme ils prennent en compte les pré-traitements tout est sauvegardé. Cela veut dire que dans le cas de nouvelles données à évaluer avec un modèle lors de la prédiction les données seront automatiquement transformées. (Voir partie utiliser de nouvelles données plus bas).

L'exemple suivant illustre un pipeline où un standard scaling est réalisé puis un PCA et enfin un DecisionTree est appliqué.

In [36]:

```
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
from sklearn.pipeline import Pipeline
from sklearn.tree import DecisionTreeClassifier

from sklearn.preprocessing import LabelEncoder

import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
```

```
url = "https://archive.ics.uci.edu/ml/machine-learning-data
names = ['SepalLengthCm', 'SepalWidthCm',
         'PetalLengthCm', 'PetalWidthCm', 'Species']
df = pd.read_csv(url, names=names)

#transformation de Species en float pour StantardScaler
class_label_encoder = LabelEncoder()
df['Species']=class_label_encoder.fit_transform(df['Species

array = df.values
X = array[:,0:4]
y = array[:,4]


print ('Création du pipeline \n')
pipeline = Pipeline([('scl', StandardScaler()),
                     ('pca', PCA(n_components=2)),
                     ('clf', DecisionTreeClassifier(random_s

validation_size=0.3 #30% du jeu de données pour le test

testsize= 1-validation_size
seed=30
X_train,X_test,y_train,y_test=train_test_split(X, y,
                                               train_size=v
                                               random_state
                                               test_size=te



pipeline.fit(X_train, y_train)
result = pipeline.predict(X_test)

print('\n accuracy:',accuracy_score(result, y_test),'\n')

```

```
Création du pipeline


 accuracy: 0.9142857142857143
```

Il est possible d'utiliser GridSearch pour chercher les meilleures valeurs dans un pré-traitement.

In [37]:

```
from sklearn.model_selection import GridSearchCV
print ('Création du pipeline \n')
pipeline = Pipeline([('pca', PCA()),
                     ('clf', DecisionTreeClassifier(random_s

grid_param = {
    'pca__n_components': [2,3]
}


gd_sr = GridSearchCV(pipeline,
                      param_grid=grid_param,
                      scoring='accuracy',
                      cv=5,
                      n_jobs=1,
                      iid=True,
                     return_train_score=True)

gd_sr.fit(X_train, y_train)

print ('meilleur score ',gd_sr.best_score_,'\n')
print ('meilleurs paramètres', gd_sr.best_params_,'\n')
print ('meilleur estimateur',gd_sr.best_estimator_,'\n')
```

```
Création du pipeline

meilleur score  0.9555555555555556

meilleurs paramètres {'pca__n_components': 2}

meilleur estimateur Pipeline(memory=None,
     steps=[('pca', PCA(copy=True, iterated_power='a
uto', n_components=2, random_state=None,
  svd_solver='auto', tol=0.0, whiten=False)), ('clf'
, DecisionTreeClassifier(class_weight=None, criterio
n='gini', max_depth=None,
            max_features=None, max_leaf_nodes=None,
            min_impurity_decrease=0.0, min_impurity_
split=None,
            min_samples_leaf=1, min_samples_split=2,
            min_weight_fraction_leaf=0.0, presort=Fa
lse, random_state=42,
            splitter='best'))])
```

Ou bien de faire les deux en même temps.

In [38]:

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
url = "https://archive.ics.uci.edu/ml/machine-learning-data
names = ['SepalLengthCm', 'SepalWidthCm',
         'PetalLengthCm', 'PetalWidthCm', 'Species']
df = pd.read_csv(url, names=names)

#transformation de Species en float pour StantardScaler
class_label_encoder = LabelEncoder()
df['Species']=class_label_encoder.fit_transform(df['Species

array = df.values
X = array[:,0:4]
y = array[:,4]

pipeline = Pipeline([('pca', PCA()),
                     ('clf', DecisionTreeClassifier())])



grid_param = [{'pca__n_components': [2,3]},
                {'clf': [DecisionTreeClassifier()],
                 'clf__max_depth': [1,2,3,4,5,6,7,8,9,10],
                 'clf__criterion': ['gini', 'entropy'],
                 'clf__min_samples_leaf': [1,2,3,4,5,6,7,8
                }]



gd_sr = GridSearchCV(estimator=pipeline,
                     param_grid=grid_param,
                     scoring='accuracy',
                     cv=5,
                     n_jobs=-1,
                    iid=True,
                    return_train_score=True)

gd_sr.fit(X_train, y_train)
print ('meilleur score ',gd_sr.best_score_,'\n')
print ('meilleurs paramètres', gd_sr.best_params_,'\n')
print ('meilleur estimateur',gd_sr.best_estimator_,'\n')
```

```
meilleur score  0.9555555555555556

meilleurs paramètres {'pca__n_components': 2}

meilleur estimateur Pipeline(memory=None,
     steps=[('pca', PCA(copy=True, iterated_power='a
uto', n_components=2, random_state=None,
  svd_solver='auto', tol=0.0, whiten=False)), ('clf'
, DecisionTreeClassifier(class_weight=None, criterio
n='gini', max_depth=None,
            max_features=None, max_leaf_nodes=None,
            min_impurity_decrease=0.0, min_impurity_
split=None,
            min_samples_leaf=1, min_samples_split=2,
            min_weight_fraction_leaf=0.0, presort=Fa
lse, random_state=None,
            splitter='best'))])
```

1.9 Sauvegarder le modèle appris

Une fois un modèle appris il est possible de le sauvegarder pour pouvoir lui appliquer d'autres données à prédire. Deux librairies existent : **pickle** et **joblib**.
Pickle est la librairie Python standard pour sérialiser-désérialiser des objets. standard Python tool for object (de)serialization. Joblib propose également de sérialiser-désérialiser des objets lorsque ceux-ci sont très volumineux.
Le choix des deux dépend des usages.

In [39]:

```
#preparation des données
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
from sklearn.naive_bayes import GaussianNB
url = "https://archive.ics.uci.edu/ml/machine-learning-data
names = ['SepalLengthCm', 'SepalWidthCm',
         'PetalLengthCm', 'PetalWidthCm', 'Species']
df = pd.read_csv(url, names=names)
array = df.values
X = array[:,0:4]
y = array[:,4]

validation_size=0.3 #30% du jeu de données pour le test

testsize= 1-validation_size
seed=30
X_train,X_test,y_train,y_test=train_test_split(X,
                                               y,
                                               train_size=
                                               random_state
                                               test_size=te


clf = GaussianNB()
clf.fit(X_train, y_train)

```

Out[39]:

```
GaussianNB(priors=None, var_smoothing=1e-09)
```

pickle

Pour sérialiser et sauvegarder le modèle appris :

In [40]:

```
import pickle
filename = 'pkl_modelNB.sav'
pickle.dump(clf, open(filename, 'wb'))
```

Pour utiliser le modèle sauvegardé :

In [41]:

```
from sklearn.metrics import accuracy_score
from sklearn.metrics import confusion_matrix
from sklearn.metrics import classification_report

clf_loaded = pickle.load(open(filename, 'rb'))
print ('Modèle chargé',clf_loaded,'\n')
result = clf_loaded.predict(X_test)

print('\n accuracy:\n')
print (accuracy_score(result, y_test),'\n')

conf = confusion_matrix(y_test, result)
print ('\n matrice de confusion \n',conf)
print ('\n',classification_report(y_test, result))

result = clf_loaded.predict([[ 5.0,  3.6,  1.4,  0.2]])
print ('\nLa prédiction du modèle pour [ 5.0,  3.6,  1.4,
       result)
```

```
Modèle chargé GaussianNB(priors=None, var_smoothing=
1e-09)


 accuracy:

0.9428571428571428


 matrice de confusion
 [[34  0  0]
 [ 0 33  5]
 [ 0  1 32]]

                precision    recall  f1-score   su
pport

    Iris-setosa       1.00      1.00      1.00
34
Iris-versicolor       0.97      0.87      0.92
38
 Iris-virginica       0.86      0.97      0.91
33

      micro avg       0.94      0.94      0.94
105
      macro avg       0.95      0.95      0.94
105
```

```
   weighted avg       0.95      0.94      0.94
105


La prédiction du modèle pour [ 5.0,  3.6,  1.4,  0.2
] est ['Iris-setosa']
```

joblib

Pour sérialiser et sauvegarder le modèle appris :

In [42]:

```
from sklearn.externals import joblib
filename = 'job_modelNB.sav'
joblib.dump(clf, filename)
```

Out[42]:

```
['job_modelNB.sav']
```

Pour utiliser le modèle sauvegardé :

In [43]:

```
from sklearn.metrics import accuracy_score
from sklearn.metrics import confusion_matrix
from sklearn.metrics import classification_report

clf_loaded = joblib.load(filename)
print (clf_loaded)
#result = clf_loaded.score(X_test, y_test)
#print(result)

result = clf_loaded.predict(X_test)

print('\n accuracy:\n')
print (accuracy_score(result, y_test),'\n')


```

```
GaussianNB(priors=None, var_smoothing=1e-09)

 accuracy:

0.9428571428571428
```

1.10 Utiliser de nouvelles données

A partir d'un modèle sauvegardé, il est donc possible d'appliquer la fonction predict pour connaître la prédiction du modèle.

Dans le cas de nouvelles données il faut faire attention car des pré-traitements ont sans doute été effectués avec les données initiales (changement d'échelle, normalisation, etc) et une matrice a été obtenue pour apprendre un modèle.

Il est impératif que les nouvelles données suivent le même traitement. Nous présentons par la suite un exemple d'utilisation à l'aide des données IRIS. Cette fois-ci nous utilisons iris qui est disponible directement dans scikit learn.

In [44]:

```
from sklearn import svm
from sklearn import datasets
from sklearn import preprocessing
from sklearn.metrics import accuracy_score
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
import pickle
from sklearn.linear_model import SGDClassifier
from sklearn.pipeline import Pipeline
from sklearn.feature_extraction.text import TfidfTransforme
from sklearn.metrics import accuracy_score, confusion_matri
from time import time
from sklearn.metrics import classification_report


```

Lecture de la base iris et utilisation de SVM comme classifieur

In [45]:

```
clf = svm.SVC(gamma='scale')
iris = datasets.load_iris()

```

Dans un premier temps nous ajoutons du bruit dans la base iris en mettant pour trois colonnes des valeurs supérieures à 1000. L'objectif ici est de montrer que les valeurs sont trop différentes pour obtenir de bons résultats de classification. Nous avons vu (Ingénierie des données) que SVM était très sensible à la standardisation.

In [46]:

```
for i in range (len(iris.data)):
    for j in range (0,2):
        val = iris.data[i][j]
        value = val*1000
        iris.data[i][j]=value
```

Définition de X et de y

In [47]:

```
X = iris.data
y = iris.target
```

In [48]:

```
validation_size=0.3 #30% du jeu de données pour le test

testsize= 1-validation_size
seed=30
X_train,X_test,y_train,y_test=train_test_split(X,
                                               y,
                                               train_size=
                                               random_stat
                                               test_size=t
```

Fonction de comptage pour voir combien d'instances sont mal classés après la classification.

In [49]:

```
def cpt_mal_classes(y_test,result):
    nb=0
    for i in range(len(y_test)):
        if y_test[i] != result [i]:
            nb=nb+1
    return nb

def print_nb_classes (taille,nb):
    print ("Taille des données",
       taille,
       " mal classés",nb)
```

Première classification avec SVM. L'objectif ici est de montrer que SVM est très sensible à la standardisation. Il suffit de regarder l'accuracy pour s'en convaincre.

In [50]:

```
clf.fit(X_train, y_train)

from sklearn.metrics import accuracy_score

result = clf.predict(X_test)
nb=cpt_mal_classes(y_test,result)
taille=len(y_test)
print_nb_classes (len(y_test),nb)
print('\n accuracy :', accuracy_score(result, y_test),'\n'
```

```
Taille des données 105  mal classés 46

 accuracy : 0.5619047619047619
```

Par la suite nous allons donc utiliser MinMaxScaler () pour standardiser les données.

Nous sauvegardons également le jeu de test (X_save=X_test.copy()). L'objectif est de sauvegarder le modèle pour évaluer en le rechargeant si le nombre d'instances bien classées est le même que celui qui a été prédit lors de l'apprentissage.

In [51]:

```
validation_size=0.3 #30% du jeu de données pour le test

testsize= 1-validation_size
seed=30
X_train,X_test,y_train,y_test=train_test_split(X,
                                               y,
                                               train_size=
                                               random_state
                                               test_size=t
```

Standadisation des données et sauvegarde du jeu de test avant le passage par la standardisation. La standardisation a été faite car les valeurs du jeu de données ne permettait pas de pouvoir utiliser le classifieur directement. En sauvegardant le jeu avant la standardisation nous simulons le fait que nous arrivons avec un nouveau jeu de données d'iris.

In [52]:

```
scaler = preprocessing.MinMaxScaler()
X_train = scaler.fit_transform(X_train)
X_save=X_test.copy()
X_test = scaler.fit_transform(X_test)
```

In [53]:

```
clf.fit(X_train, y_train)

result = clf.predict(X_test)
nb=cpt_mal_classes(y_test,result)
taille=len(y_test)
print_nb_classes (len(y_test),nb)
print('\n accuracy :', accuracy_score(result, y_test),'\n'
```

```
Taille des données 105  mal classés 5

 accuracy : 0.9523809523809523
```

Sauvegarde du modèle appris

In [54]:

```
print("\nSauvegarde du modèle")
filename = 'firstmodel.pkl'
pickle.dump(clf, open(filename, 'wb'))


```

```
Sauvegarde du modèle
```

Ouverture du modèle pour le tester. Ici nous reprenons le jeu de test qui n'a pas eu l'étape de standardisation comme nouvelles données, i.e. nous avons de nouveaux IRIS. Si le modèle est bien appris le nombre d'objets mal classés devrait être le même.

In [55]:

```
print ("Chargement du modèle \n")
filename = 'firstmodel.pkl'
clf_loaded = pickle.load(open(filename, 'rb'))

result=clf_loaded.predict(X_save)

nb=cpt_mal_classes(y_test,result)
taille=len(y_test)
print_nb_classes (len(y_test),nb)
```

```
Chargement du modèle

Taille des données 105  mal classés 72
```

Nous pouvons constater qu'il y a plus d'objets mal classés. Comme nous avons fait une standardisation dans les étapes précédentes celle là n'a pas pu être faite pour les nouvelles données. La standardisation doit donc être faite pour les nouvelles données mais elle nécessite de pouvoir récupérer les anciennes valeurs pour tout standardiser.

Les pipelines sont donc utiles pour pouvoir tout sauvegarder (l'étape de standardisation et l'application du modèle).

In [56]:

```
pipeline = Pipeline([('vect', preprocessing.MinMaxScaler()
                 ('clf', svm.SVC(gamma='scale')),
                ])



X=iris.data
y=iris.target


X_train,X_test,y_train,y_test=train_test_split(X,
                                               y,
                                               train_size=
                                               random_stat
                                               test_size=t


X_save=X_test.copy()

pipeline.fit(X_train, y_train)

result = pipeline.predict(X_test)

nb=cpt_mal_classes(y_test,result)
taille=len(y_test)
print_nb_classes (len(y_test),nb)
print('\n accuracy:',accuracy_score(result, y_test),'\n')


print("\nSauvegarde du pipeline ")
filename = 'avecscaler.pkl'
pickle.dump(pipeline, open(filename, 'wb'))
```

```
Taille des données 105  mal classés 5

 accuracy: 0.9523809523809523


Sauvegarde du pipeline
```

In [57]:

```
print ("Chargement du modèle \n")
filename = 'avecscaler.pkl'
clf_loaded = pickle.load(open(filename, 'rb'))

result=clf_loaded.predict(X_save)
nb=cpt_mal_classes(y_test,result)
taille=len(y_test)
print_nb_classes (len(y_test),nb)


```

```
Chargement du modèle

Taille des données 105  mal classés 5
```

REMARQUE TRES IMPORTANTE :
Attention, si vous testez ce modèle sauvegardé sous ce notebook il fonctionnera. Si, par exemple, vous ouvrez un fichier à part et lancer le code précédent cela fonctionnera, sans doute, encore* * mais .....
Imaginer que l'on réalise un traitement particulier, via une fonction f () dans nos données, qui soit appelée dans le pipeline :
pipeline = Pipeline([('vect', f()),
Si maintenant vous utilisez dans votre autre notebook ou dans un programme extérieur votre modèle. Alors qu'il fonctionnait bien dans votre notebook précédent, vous verrez afficher un message d'erreur du type : *Can't get attribute 'f'*
En fait, pickle sauvegarde une référence à la fonction f. Dans le premier cas, votre notebook initial cette fonction a été définie et donc pickle va pouvoir exécuter le code de cette fonction. Dans l'autre notebook, il va rechercher le code à exécuter et donc ... il ne le trouvera pas.

Il est possible d'utiliser *Drill* qui se comporte exactement de la même manière que *pickle* mais qui lui sauvegarde aussi la fonction. Alors la solution est-elle d'utiliser *Drill* ? C'est tout à fait déconseillé. Bien sûr pour votre modèle avec votre fonction il n'y aura pas de problèmes mais souvent on va utiliser des modèles définis par quelqu'un d'autre .... et pour des raisons de sécurités évidentes (on ne sait pas ce que fait la fonction cachée !!!) ... on évite cette approche. La solution consiste tout simplement à sauvegarder le modèle et les fonctions nécessaires pour son fonctionnement et de faire un import de celles-ci là où le modèle est utilisé.

Une notebook spécifique sera bientôt mis à votre disposition sur ce point.
* * le code fonctionne car dans votre autre notebook il y a de grandes chances que vous importiez des fonctions de scikitlearn et que les traitements réalisés sur nos Iris sont réalisées via des fonctions très classiques (noramlisation).

Premières classifications

Le but de ce notebook est de faire des premières classifications. Pour cela nous utilisons le jeu de données IRIS qui est très connu dans la communauté.

Dans un premier temps, nous présentons une première classification pour apprendre à utiliser un classifieur et à prédire une valeur. Les jeux de données d'apprentissage et de de test sont présentés par la suite. Nous présentons ensuite différentes mesures pour évaluer un modèle.
Etant donné qu'il n'est pas possible d'avoir un classifieur universel (NO FREE LUNCH THEOREM), nous verrons comment utiliser différents classifieurs et comment rechercher les meilleurs paramètres d'un classifieur. Enfin nous verrons comment sauvegarder et ré-utiliser un modèle appris.

In [1]:

Le jeu de données IRIS

Nous considérons par la suite le jeu de données des IRIS

In [2]:

	SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm	Spec
0	5.1	3.5	1.4	0.2	set
1	4.9	3.0	1.4	0.2	set
2	4.7	3.2	1.3	0.2	set
3	4.6	3.1	1.5	0.2	set
4	5.0	3.6	1.4	0.2	set

Toute première classification

La classification supervisée considère les données sous la forme (X
,Y
) où X
correspond aux variables prédictives et Y
le résultat d'une observation, i.e. la variable à prédire. En se basant sur un jeu d'apprentissage, un algorithme de classification supervisée cherche une fonction mathématique F
qui permet de transformer (au mieux) X
vers Y
, i.e. $F(X) \approx Y$
.

Convention : les variables prédictives sont celles associées aux objets, généralement stockées sous la forme d'une matrice aussi, par convention, elles sont souvent notées en majuscule (notation d'une matrice). Les variables à prédire sont généralement stockées dans un vecteur et sont souvent notées avec une lettre majuscle (notation d'un vecteur).

Autrement il est tout à fait possible d'utiliser des noms de variables significatives comme data, target.

In [3]:

Dans scikit-learn, pour apprendre un modèle, un estimateur est créé en appelant sa méthode *fit(X, y)*.
Dans l'exemple qui suit nous utilisons un classifieur naïve Bayes (https://scikit-learn.org/stable/modules/naive_bayes.html) (https://scikit-learn.org/stable/modules/naive_bayes.html)).

In [4]:

Out[4]:

```
GaussianNB(priors=None, var_smoothing=1e-09)
```

La ligne affichée dans le Out indique les hyperparamètres du classifieur s'ils existent. Il est également possible de les obtenir à l'aide de :

In [5]:

Out[5]:

```
{'priors': None, 'var_smoothing': 1e-09}
```

Il est alors possible de prédire une valeur non lue à l'aide de la méthode *predict*. Par exemple, nous savons que les valeurs du 5ième IRIS sont 5.0, 3.6, 1.4, 0.2 et qu'il appartient à la classe Iris-setosa.

In [6]:

```
La prédiction du modèle pour [ 5.0,  3.6,  1.4,  0.2
] est ['Iris-setosa']
```

Test de la prédiction sur les données d'apprentissage.

In [7]:

```
['Iris-setosa' 'Iris-setosa' 'Iris-setosa' 'Iris-set
osa' 'Iris-setosa'
 'Iris-setosa' 'Iris-setosa' 'Iris-setosa' 'Iris-set
osa' 'Iris-setosa'
 'Iris-setosa' 'Iris-setosa' 'Iris-setosa' 'Iris-set
osa' 'Iris-setosa'
 'Iris-setosa' 'Iris-setosa' 'Iris-setosa' 'Iris-set
osa' 'Iris-setosa'
 'Iris-setosa' 'Iris-setosa' 'Iris-setosa' 'Iris-set
osa' 'Iris-setosa'
 'Iris-setosa' 'Iris-setosa' 'Iris-setosa' 'Iris-set
osa' 'Iris-setosa'
 'Iris-setosa' 'Iris-setosa' 'Iris-setosa' 'Iris-set
osa' 'Iris-setosa'
 'Iris-setosa' 'Iris-setosa' 'Iris-setosa' 'Iris-set
osa' 'Iris-setosa'
 'Iris-setosa' 'Iris-setosa' 'Iris-setosa' 'Iris-set
osa' 'Iris-setosa'
 'Iris-setosa' 'Iris-setosa' 'Iris-setosa' 'Iris-set
osa' 'Iris-setosa'
```

Une première évaluation de la qualité de la prédiction peut se faire avec le calcul de l'*accuracy* (pourcentage de prédictions correctes).

In [8]:

```
accuracy:  0.96
```

Comme nous pouvons le constater, même sur le jeu d'apprentissage il y a des erreurs dans le modèle appris. Pour connaître les objets mal classés :

In [9]:

```
Les objets mal classés sont :

 52     Iris-versicolor
70     Iris-versicolor
77     Iris-versicolor
106     Iris-virginica
119     Iris-virginica
133     Iris-virginica
Name: Species, dtype: object



 [ 52  70  77 106 119 133] classé en  ['Iris-virgini
ca' 'Iris-virginica' 'Iris-virginica' 'Iris-versicol
or'
 'Iris-versicolor' 'Iris-versicolor']
```

Jeu d'apprentissage et de test

In [10]:

En classification, il est indispensable de créer un jeu d'apprentissage sur lequel un modèle est appris et un jeu de test pour évaluer le modèle. La fonction *train_test_split* permet de décomposer le jeu de données en 2 groupes : les données pour l'apprentissage et les données pour les tests.

Le paramètre *train_size* indique la taille du jeu d'apprentissage qui sera utilisé.
le paramètre *random_state* spécifie un entier germe du nombre aléatoire pour le tirage. S'il n'est pas spécifié sickit learn utilise un générateur de nombre aléatoire à partir de np.random.

Depuis la version 0.21 il est également nécessaire de préciser la taille du jeu de test_size. De manière classique ce nombre est égal à la différence entre la taille du jeu de données - le test_size (1-test_size). Via cette fonctionnalité sickit learn permet de faire de l'échantillonage sur le jeu d'apprentissage.

Dans notre exemple nous prenons 30% du jeu de données comme jeu de test.

In [11]:

```
```

L'apprentissage du modèle se fait comme précédemment

In [12]:

```
```

Out[12]:

```
GaussianNB(priors=None, var_smoothing=1e-09)
```

De même pour la prédiction

In [13]:

```
```

```
accuracy : 0.9428571428571428
```

Le problème essentiel de cette approche est que le modèle est appris sur un seul jeu de données et qu'en fonction de la sélection les résultats peuvent être très différents. La bonne solution consiste à utiliser la **cross validation**. Dans notre cas, nous allons utiliser une 10-fold cross validation pour évaluer la qualité. Le jeu de données sera découpé en 10 partie, entrainé sur 9, testé sur 1 et cela sera répété pour toutes les combinaisons du découpage.

In [14]:

In [15]:

```
Les différentes accuracy pour les 10 évaluations son
t :
 [0.8        0.86666667 1.         1.         0.9333
3333 1.
 1.         1.         0.93333333 1.        ]

Accuracy moyenne :  0.9533333333333334  standard dev
iation 0.06699917080747259
```

L'écart type (standard deviation) est très important car il montre les grandes variations qui peuvent exister par rapport aux jeux de données.

Plus loin sur l'évaluation d'un modèle

L'accuracy (nombre d'objets correctement classés) est la métrique la plus simple pour comprendre le résultat de la classification mais ne tient pas du tout compte de la distribution des données et ne permet pas d'indiquer les erreurs. Par exemple avec des classes très déséquilibrées (1 vs 99), nous pouvons avoir un modèle avec une accuracy de 99% mais lorsque qu'un objet de la classe intervient nous ne pouvons pas le retrouver.

Par la suite, par simplification, nous reprenons une classification réalisée sans cross validation mais le principe est évidemment le même avec cross validation. Nous introduisons la matrice de correlation et les différentes mesures : precision, rappel et F1-score.

In [16]:

```
accuracy: 0.9428571428571428
```

La matrice de confusion permet de connaître les objets bien ou mal classés. Il suffit d'utiliser la fonction *confusion_matrix*.

In [17]:

```
matrice de confusion
[[34  0  0]
 [ 0 33  5]
 [ 0  1 32]]
```

Il est possible d'obtenir plus d'information : *precision*, *recall* et *f1-measure* à l'aide de *classification_report*.

In [18]:

```
 matrice de confusion
 [[34  0  0]
 [ 0 33  5]
 [ 0  1 32]]

                 precision    recall  f1-score   su
pport

    Iris-setosa       1.00      1.00      1.00
34
Iris-versicolor       0.97      0.87      0.92
38
 Iris-virginica       0.86      0.97      0.91
33

      micro avg       0.94      0.94      0.94
105
      macro avg       0.95      0.95      0.94
```

Rappel :
Considérons une matrice de confusion dans un cas binaire. Par exemple présence de SPAM ou non dans des mails.

N = 115	**PREDIT NON**	**PREDIT OUI**
REEL NON	60	10
REEL OUI	5	40

La matrice nous permet de voir qu'il y a deux classes prédites (OUI ou NON). Le classifieur fait un total de 115 prédictions. Sur ces 115 cas, le classifieur a prédit OUI 50 fois et NON 65 fois. En fait 45 documents sont des SPAMS et 70 ne le sont pas.

TP (True positive) : il s'agit des objets qui étaient prédits OUI (il s'agit de SPAM) et qui sont effectivement des SPAM.
TN (True negative) : il s'agit des objets qui étaient prédits NON (il ne s'agit pas de SPAM) et qui effectivement ne sont pas des SPAM.
FP (False positive) : il s'agit des objets qui étaient prédits comme SPAM mais qui en fait n'étaient pas des SPAM.

FN (False negative) : il s'agit des objets qui étaient prédits comme non SPAM qui en fait s'avèrent être des SPAM.
Dans la matrice ci-dessous ces éléments sont reportés :

$N =$ 115	**PREDIT NON**	**PREDIT OUI**	
REEL NON	$TN = 60$	$FP = 10$	70
REEL OUI	$FN = 5$	$TP = 40$	45
	65	50	

L'**accuracy** correspond au pourcentage de prédiction correcte. Elle est définie par

$$\frac{TP + TN}{TN + FP + FN + TP} = \frac{40 + 60}{60 + 10 + 5 + 40} = 0.86.$$

Le **recall** (ou sensitivity ou True Positive Rate ou rappel) correspond au nombre d' objets pertinents retrouvés par rapport aux nombres d'objets pertinents du jeu de données. Dans notre cas, pour tous les OUI présents combien de fois le OUI a t'il été prédit ?

$$recall = \frac{Nombre\ de\ SPAM\ correctement\ reconnus}{Nombre\ total\ de\ SPAM\ dans\ le\ jeu\ de\ données} = \frac{TP}{FN + TP} = \frac{40}{40 + 5} = 0.88.$$

La **precision** correspond à la proportion d'objets pertinents parmi les objets sélectionné. Tous les objets retournés non pertinents constituent du bruit.

$$precision = \frac{Nombre\ de\ SPAM\ correctement\ reconnus}{Nombre\ de\ fois\ où\ un\ objet\ a\ été\ prédit\ SPAM} = \frac{TP}{TP + FP} = \frac{40}{40 + 10} = 0.8.$$

Le **f1-score** (ou f-measure) est la moyenne harmonique du rappel et de la précision.

$$f1 - score = 2 \times \frac{precision \times recall}{precision + recall} = 2 \times \frac{0.8 \times 0.88}{0.8 + 0.88}.$$

Dans le cas d'une classification multiclasse, à partir de la matrice de confusion, la precision est calculée, pour une colonne i
, par :

$$precision_i = \frac{M_{ii}}{\sum_j M_{ji}}$$

et le recall par :

$$recall_i = \frac{M_{ii}}{\sum_j M_{ij}}$$

Pour la matrice de confusion suivante :

$$\begin{matrix} Iris-setosa & 34 & 0 & 0 \\ Iris-versicolor & 0 & 33 & 5 \\ Iris-virginica & 0 & 1 & 32 \end{matrix}$$

classification_report retourne le résultat suivant :

	$precision$	$recall$	$f1-score$	$support$
$Iris-setosa$	1.00	1.00	1.00	34
$Iris-versicolor$	0.97	0.87	0.92	38
$Iris-virginica$	0.86	0.97	0.91	33
$avg/total$	0.95	0.94	0.94	105

La precision d'Iris-versicolor est obtenue par :

$$precision_i = \frac{M_{ii}}{\sum_j M_{ji}} = \frac{33}{33+1} = 0.97.$$

Le rappel d'Iris-versicolor est obtenue par :

$$recall_i = \frac{M_{ii}}{\sum_j M_{ij}} = \frac{33}{33+5} = 0.87.$$

La precision d'Iris-virginica est obtenue par :

$$precision_i = \frac{M_{ii}}{\sum_j M_{ji}} = \frac{32}{32+5} = 0.86.$$

Le rappel d'Iris-versicolor est obtenue par :

$$recall_i = \frac{M_{ii}}{\sum_j M_{ij}} = \frac{32}{32+1} = 0.96.$$

Pour connaître les objets mal classés :

In [19]:

```
Les objets mal classés sont :

 52     Iris-versicolor
56     Iris-versicolor
70     Iris-versicolor
77     Iris-versicolor
83     Iris-versicolor
106     Iris-virginica
119     Iris-virginica
Name: Species, dtype: object



 [ 52  56  70  77  83 106 119] classé en  ['Iris-vir
ginica' 'Iris-virginica' 'Iris-virginica' 'Iris-virg
inica'
 'Iris-virginica' 'Iris-versicolor' 'Iris-versicolor
']
```

Pour afficher, avec seaborn, la matrice de confusion.

In [20]:

```
<Figure size 1000x600 with 2 Axes>
```

Les métriques peuvent être appelées indépendamment. Par exemple
from sklearn.metrics import precision_score
print("Precision score: {}".format(precision_score(y_true,y_pred)))
ou à l'aide de la fonction *precision_recall_fscore_support*

In [21]:

```
precision: [1.         0.97058824 0.86486486]
recall: [1.         0.86842105 0.96969697]
fscore: [1.         0.91666667 0.91428571]
support: [34 38 33]
```

Remarque : il existe, bien entendu, d'autres mesures pour évaluer un classifieur. Par exemple, la sensiblité, la spécificité, l'air sous la courbe roc (AUC), l'indice de Gini (voir cours).

Utiliser plusieurs classifiers

Comme l'indique le NO FREE LUNCH THEOREM il n'existe pas un classifieur universel et en fonction des données il est souvent nécessaire d'en évaluer plusieurs pour retenir le plus efficace. Le principe est similaire au précédent, il suffit de les mettre dans une structure et de boucler dessus.

In [22]:

Dans l'exemple, nous utilison LogisticRegression, DecisionTree, KNeighbors, GaussianNB et SVM.
Les paramètres utilisés pour chacune des approches sont ceux par défaut. Pour chaque approche nous faisons une cross validation de 10.

In [23]:

In [24]:

```
Time pour LR   0.15139937400817871
LR: 0.900000 (0.116428)
Time pour KNN   0.019014120101928711
KNN: 0.933333 (0.084327)
Time pour CART   0.011366367340087891
CART: 0.946667 (0.065320)
Time pour NB   0.018451929092407227
NB: 0.946667 (0.058119)
Time pour SVM   0.012649774551391602
SVM: 0.953333 (0.052068)
```

In [25]:

Out[25]:

```
[Text(0, 0, 'LR'),
 Text(0, 0, 'KNN'),
 Text(0, 0, 'CART'),
 Text(0, 0, 'NB'),
 Text(0, 0, 'SVM')]
```

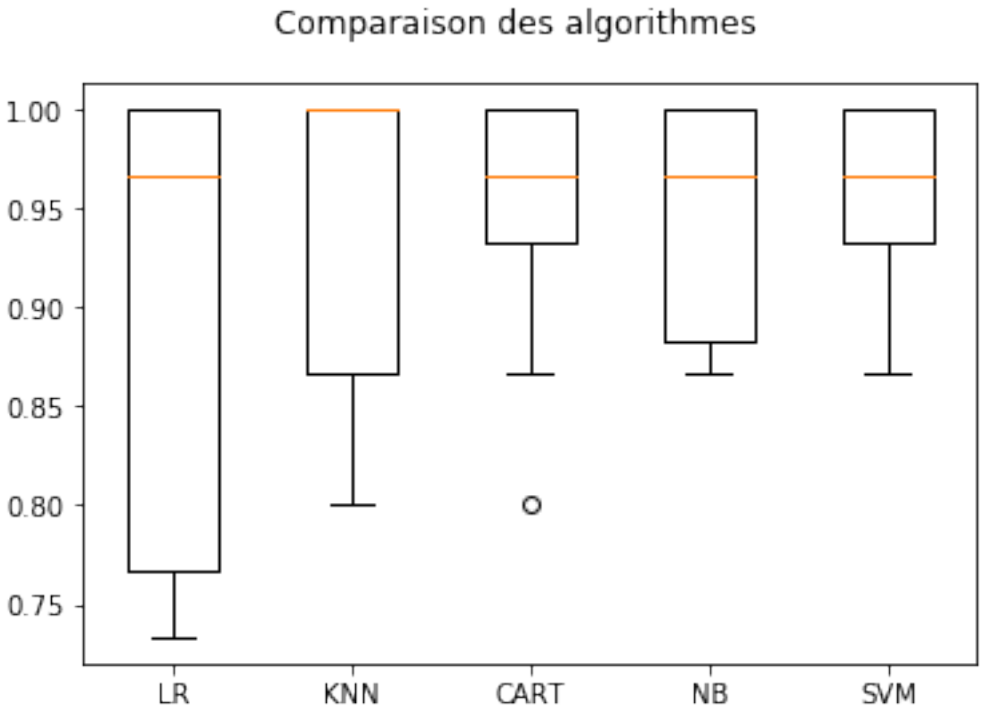

Comme SVM donne des meilleurs résultats, nous pouvons l'utiliser comme modèle de prédiction.

In [26]:

```
 accuracy:  0.9619047619047619


 matrice de confusion
 [[34  0  0]
 [ 0 34  4]
 [ 0  0 33]]

                 precision    recall  f1-score   su
pport

    Iris-setosa       1.00      1.00      1.00
34
Iris-versicolor       1.00      0.89      0.94
38
 Iris-virginica       0.89      1.00      0.94
33

       .              0.96      0.96      0.96
```

Les hyperparamètres

Dans l'approche précédente nous avons pris les valeurs par défaut pour les différents classifieurs. Cependant en fonction des paramètres du classifieur les résultats peuvent être complétement différents (choix du noyeau SVM, nombre de K dans KNeighbors, etc.). Sikit learn permet de pouvoir faire une recherche exhaustive (grid search) pour trouver les paramètres les plus pertinents pour un classifieur.

In [27]:

Considérons un arbre de décision. Les principaux paramètres sont le critère pour découper (gini ou entropy), la profondeur maximale de l'arbre, et le nombre d'échantillons par feuille. Il faut, dans un premier temps, initialiser les variables à tester dans un dictionnaire.
Le test de toutes les valeurs se fait à l'aide de la fonction *GridSearchCV*. Ele prend commme paramètre le classifieur, le dictionnaire ds paramètre, le type de scoring, le nombre de crossvalidation.

Quelques paramètres souvent utilisés :

- *n_jobs* : (par défaut 1) nombre de coeurs à utiliser pour effectuer les calculs, dépend du cpu. Si la machine possède plusieurs coeurs, il est possible d'indiquer de tous les utiliser en mettant *n_jobs=-1*
- *verbose* : affichage du déroulement des calculs, 0 = silent.
- *random_state* : si le classifieur utilisé utilise de l'aléatoire, random_state permet de fixer le générateur pour reproduire les résultats.

Un grid search est long à obtenir dans la mesure où il faut essayer l'ensemble des cas. La possibilité de répartir sur plusieurs processeur permet de faire gagner beaucoup de temps.

In [28]:

Out[28]:

```
GridSearchCV(cv=5, error_score='raise-deprecating',
       estimator=DecisionTreeClassifier(class_weight
=None, criterion='gini', max_depth=None,
            max_features=None, max_leaf_nodes=None,
            min_impurity_decrease=0.0, min_impurity_
split=None,
            min_samples_leaf=1, min_samples_split=2,
            min_weight_fraction_leaf=0.0, presort=Fa
lse, random_state=None,
            splitter='best'),
       fit_params=None, iid=True, n_jobs=-1,
       param_grid={'max_depth': [1, 2, 3, 4, 5, 6, 7
, 8, 9, 10], 'criterion': ['gini', 'entropy'], 'min_
samples_leaf': [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]},
       pre_dispatch='2*n_jobs', refit=True, return_t
rain_score=True,
       scoring='accuracy', verbose=0)
```

Pour connaître les meilleures conditions :

In [29]:

```
meilleur score  0.9777777777777777

meilleurs paramètres {'criterion': 'gini', 'max_dept
h': 2, 'min_samples_leaf': 1}

meilleur estimateur DecisionTreeClassifier(class_wei
ght=None, criterion='gini', max_depth=2,
            max_features=None, max_leaf_nodes=None,
            min_impurity_decrease=0.0, min_impurity_
split=None,
            min_samples_leaf=1, min_samples_split=2,
            min_weight_fraction_leaf=0.0, presort=Fa
lse, random_state=None,
            splitter='best')
```

Avec KNeighborsClassifier()

In [30]:

```
meilleur score  1.0

meilleurs paramètres {'metric': 'minkowski', 'n_neig
hbors': 1}

meilleur estimateur KNeighborsClassifier(algorithm='
auto', leaf_size=30, metric='minkowski',
           metric_params=None, n_jobs=None, n_neighb
ors=1, p=2,
           weights='uniform')
```

Avec SVM

In [31]:

```
meilleur score  1.0

meilleurs paramètres {'C': 1, 'gamma': 0.001, 'kerne
l': 'linear'}

meilleur estimateur SVC(C=1, cache_size=200, class_w
eight=None, coef0=0.0,
  decision_function_shape='ovr', degree=3, gamma=0.0
01, kernel='linear',
  max_iter=-1, probability=False, random_state=None,
shrinking=True,
  tol=0.001, verbose=False)
```

Pour voir l'ensemble des évaluations effectuées par GridSearchCV :

In [32]:

	mean_fit_time	mean_score_time	mean_test_score	mean_train_score
0	0.000950	0.000479	0.444444	0.452069
1	0.000517	0.000292	0.444444	0.452069
2	0.000436	0.000277	0.444444	0.452069
3	0.000468	0.000308	0.444444	0.452069
4	0.000377	0.000345	0.444444	0.452069

5 rows × 23 columns

L'avantage de GridSearchCV est qu'il va parcourir toutes les conditions et retourner celles qui sont les meilleures pour la ou les mesures de scoring recherchée (dans notre cas nous avons privilégié l'accuracy). Cela est très pratique mais est malheureusement impossible dans certains cas car beaucoup trop long à mettre en place. Une solution possible est d'utiliser *RandomizedSearchCV* qui parcourt de manière aléatoire l'espace de recherche. Il suffit dans ce cas de spécifier des tirages aléatoires pour les valeurs possibles des paramètres et de préciser le nombre d'itérations voulues. Le second usage de *RandomizedSearchCV* est, lorsque l'on n'a pas une très bonne idée de ce que cela peut donner ou des paramètres à utiliser de faire appel à lui pour avoir des valeurs qui peuvent être significatives et de faire suivre à partir de ces valeurs une recherche via *GridSearchCV*.

In [33]:

```
meilleur score  0.9555555555555556

meilleurs paramètres {'criterion': 'entropy', 'max_d
epth': 16, 'min_samples_leaf': 1}

meilleur estimateur DecisionTreeClassifier(class_wei
ght=None, criterion='entropy', max_depth=16,
            max_features=None, max_leaf_nodes=None,
            min_impurity_decrease=0.0, min_impurity_
split=None,
            min_samples_leaf=1, min_samples_split=2,
            min_weight_fraction_leaf=0.0, presort=Fa
lse, random_state=None,
            splitter='best')
```

	mean_fit_time	mean_score_time	mean_test_score	mean_train_score	param_criterion

Gridsearch et plusieurs classifieurs

Il est tout à fait possible d'utiliser Gridsearch avec plusieurs classifieurs. Il suffit pour cela d'initaliser les classifiers dans un biblitothèse et faire de même pour les paramètres.

In [34]:

In [35]:

```
Le meilleur resultat :

Classifier :  KNeighborsClassifier  score 1.00  avec
KNeighborsClassifier(algorithm='auto', leaf_size=30,
metric='minkowski',
           metric_params=None, n_jobs=None, n_neighb
ors=1, p=2,
           weights='uniform')

Tous les résultats :

Classifier :  KNeighborsClassifier  score 1.00  avec
KNeighborsClassifier(algorithm='auto', leaf_size=30,
metric='minkowski',
           metric_params=None, n_jobs=None, n_neighb
ors=1, p=2,
           weights='uniform')

Classifier :  SVC  score 1.00  avec  SVC(C=1, cache_
```

Les pipelines

Il peut arriver que différentes combinaisons de pré-traitements puissent être utilisées. Par exemple il est possible d'utiliser du changement d'échelle, du PCA (projection sur un nombre différent de dimensions), de faire du remplacement de valeurs manquantes ...

L'objectif du pipeline est de pouvoir regrouper l'ensemble de ces prétraitements et de pouvoir les faire suivre par le classifier. Le principe consiste à d'abord mettre la chaîne de pré-traitement, d'ensuite mettre le classifier et d'utiliser directement le pipeline.

Attention les pipelines sont très importants lorsque l'on sauvegarde un modèle. En effet comme ils prennent en compte les pré-traitements tout est sauvegardé. Cela veut dire que dans le cas de nouvelles données à évaluer avec un modèle lors de la prédiction les données seront automatiquement transformées. (Voir partie utiliser de nouvelles données plus bas).

L'exemple suivant illustre un pipeline où un standard scaling est réalisé puis un PCA et enfin un DecisionTree est appliqué.

In [36]:

```
Création du pipeline


 accuracy: 0.9142857142857143
```

Il est possible d'utiliser GridSearch pour chercher les meilleures valeurs dans un pré-traitement.

In [37]:

```
Création du pipeline

meilleur score  0.9555555555555556

meilleurs paramètres {'pca__n_components': 2}

meilleur estimateur Pipeline(memory=None,
     steps=[('pca', PCA(copy=True, iterated_power='a
uto', n_components=2, random_state=None,
  svd_solver='auto', tol=0.0, whiten=False)), ('clf'
, DecisionTreeClassifier(class_weight=None, criterio
n='gini', max_depth=None,
            max_features=None, max_leaf_nodes=None,
            min_impurity_decrease=0.0, min_impurity_
split=None,
            min_samples_leaf=1, min_samples_split=2,
            min_weight_fraction_leaf=0.0, presort=Fa
lse, random_state=42,
            splitter='best'))])
```

Ou bien de faire les deux en même temps.

In [38]:

```
meilleur score  0.9555555555555556

meilleurs paramètres {'pca__n_components': 2}

meilleur estimateur Pipeline(memory=None,
     steps=[('pca', PCA(copy=True, iterated_power='a
uto', n_components=2, random_state=None,
  svd_solver='auto', tol=0.0, whiten=False)), ('clf'
, DecisionTreeClassifier(class_weight=None, criterio
n='gini', max_depth=None,
            max_features=None, max_leaf_nodes=None,
            min_impurity_decrease=0.0, min_impurity_
split=None,
            min_samples_leaf=1, min_samples_split=2,
            min_weight_fraction_leaf=0.0, presort=Fa
lse, random_state=None,
            splitter='best'))])
```

Sauvegarder le modèle appris

Une fois un modèle appris il est possible de le sauvegarder pour pouvoir lui appliquer d'autres données à prédire. Deux librairies existent : **pickle** et **joblib**.
Pickle est la librairie Python standard pour sérialiser-désérialiser des objets. standard Python tool for object (de)serialization. Joblib propose également de sérialiser-désérialiser des objets lorsque ceux-ci sont très volumineux.
Le choix des deux dépend des usages.

In [39]:

Out[39]:

```
GaussianNB(priors=None, var_smoothing=1e-09)
```

pickle

Pour sérialiser et sauvegarder le modèle appris :

In [40]:

Pour utiliser le modèle sauvegardé :

In [41]:

```
Modèle chargé GaussianNB(priors=None, var_smoothing=
1e-09)


 accuracy:

0.9428571428571428


 matrice de confusion
 [[34  0  0]
 [ 0 33  5]
 [ 0  1 32]]

                precision    recall  f1-score   su
pport

    Iris-setosa       1.00      1.00      1.00
34
Iris-versicolor       0.97      0.87      0.92
```

joblib

Pour sérialiser et sauvegarder le modèle appris :

In [42]:

Out[42]:

```
['job_modelNB.sav']
```

Pour utiliser le modèle sauvegardé :

In [43]:

```
GaussianNB(priors=None, var_smoothing=1e-09)

 accuracy:

0.9428571428571428
```

Utiliser de nouvelles données

A partir d'un modèle sauvegardé, il est donc possible d'appliquer la fonction predict pour connaître la prédiction du modèle.

Dans le cas de nouvelles données il faut faire attention car des pré-traitements ont sans doute été effectués avec les données initiales (changement d'échelle, normalisation, etc) et une matrice a été obtenue pour apprendre un modèle.

Il est impératif que les nouvelles données suivent le même traitement. Nous présentons par la suite un exemple d'utilisation à l'aide des données IRIS. Cette fois-ci nous utilisons iris qui est disponible directement dans scikit learn.

In [44]:

Lecture de la base iris et utilisation de SVM comme classifieur

In [45]:

Dans un premier temps nous ajoutons du bruit dans la base iris en mettant pour trois colonnes des valeurs supérieures à 1000. L'objectif ici est de montrer que les valeurs sont trop différentes pour obtenir de bons résultats de classification. Nous avons vu (Ingénierie des données) que SVM était très sensible à la standardisation.

In [46]:

Définition de X et de y

In [47]:

In [48]:

Fonction de comptage pour voir combien d'instances sont mal classés après la classification.

In [49]:

Première classification avec SVM. L'objectif ici est de montrer que SVM est très sensible à la standardisation. Il suffit de regarder l'accuracy pour s'en convaincre.

In [50]:

```
Taille des données 105  mal classés 46

 accuracy : 0.5619047619047619
```

Par la suite nous allons donc utiliser MinMaxScaler () pour standardiser les données.

Nous sauvegardons également le jeu de test (X_save=X_test.copy()). L'objectif est de sauvegarder le modèle pour évaluer en le rechargeant si le nombre d'instances bien classées est le même que celui qui a été prédit lors de l'apprentissage.

In [51]:

Standadisation des données et sauvegarde du jeu de test avant le passage par la standardisation. La standardisation a été faite car les valeurs du jeu de données ne permettait pas de pouvoir utiliser le classifieur directement. En sauvegardant le jeu avant la standardisation nous simulons le fait que nous arrivons avec un nouveau jeu de données d'iris.

In [52]:

In [53]:

```
Taille des données 105  mal classés 5

 accuracy : 0.9523809523809523
```

Sauvegarde du modèle appris

In [54]:

```
Sauvegarde du modèle
```

Ouverture du modèle pour le tester. Ici nous reprenons le jeu de test qui n'a pas eu l'étape de standardisation comme nouvelles données, i.e. nous avons de nouveaux IRIS. Si le modèle est bien appris le nombre d'objets mal classés devrait être le même.

In [55]:

```
Chargement du modèle

Taille des données 105  mal classés 72
```

Nous pouvons constater qu'il y a plus d'objets mal classés. Comme nous avons fait une standardisation dans les étapes précédentes celle là n'a pas pu être faite pour les nouvelles données. La standardisation doit donc être faite pour les nouvelles données mais elle nécessite de pouvoir récupérer les anciennes valeurs pour tout standardiser.

Les pipelines sont donc utiles pour pouvoir tout sauvegarder (l'étape de standardisation et l'application du modèle).

In [56]:

```
Taille des données 105  mal classés 5

 accuracy: 0.9523809523809523


Sauvegarde du pipeline
```

In [57]:

```
Chargement du modèle

Taille des données 105  mal classés 5
```

REMARQUE TRES IMPORTANTE :
Attention, si vous testez ce modèle sauvegardé sous ce notebook il fonctionnera. Si, par exemple, vous ouvrez un fichier à part et lancer le code précédent cela fonctionnera, sans doute, encore * mais .....
Imaginer que l'on réalise un traitement particulier, via une fonction f () dans nos données, qui soit appelée dans le pipeline :
pipeline = Pipeline([('vect', f()),
Si maintenant vous utilisez dans votre autre notebook ou dans un programme extérieur votre modèle. Alors qu'il fonctionnait bien dans votre notebook précédent, vous verrez afficher un message d'erreur du type : *Can't get attribute 'f'*
En fait, pickle sauvegarde une référence à la fonction f. Dans le premier cas, votre notebook initial cette fonction a été définie et donc pickle va pouvoir exécuter le code de cette fonction. Dans l'autre notebook, il va rechercher le code à exécuter et donc ... il ne le trouvera pas.

Il est possible d'utiliser *Drill* qui se comporte exactement de la même manière que *pickle* mais qui lui sauvegarde aussi la fonction. Alors la solution est-elle d'utiliser *Drill* ? C'est tout à fait déconseillé. Bien sûr pour votre modèle avec votre fonction il n'y aura pas de problèmes mais souvent on va utiliser des modèles définis par quelqu'un d'autre .... et pour des raisons de sécurités évidentes (on ne sait pas ce que fait la fonction cachée !!!) ... on évite cette approche. La solution consiste tout simplement à sauvegarder le modèle et les fonctions nécessaires pour son fonctionnement et de faire un import de celles-ci là où le modèle est utilisé.

Une notebook spécifique sera bientôt mis à votre disposition sur ce point.
* le code fonctionne car dans votre autre notebook il y a de grandes chances que vous importiez des fonctions de scikitlearn et que les traitements réalisés sur nos Iris sont via des fonctions très classiques.