TP 1 - Analyse d'un jeu de données

Nous allons dans ce TP analyser le jeu de données Titanic qui est très largement utilisé dans la communauté. Il concerne les informations concernant les personnes qui étaient à bord du Titanic.
Les différentes colonnes sont les suivantes :
survival: Survival (0 = No; 1 = Yes)
pclass: Passenger Class (1 = 1st; 2 = 2nd; 3 = 3rd)
name: Name
sex: Sex
age: Age
sibsp: Number of Siblings/Spouses Aboard
parch: Number of Parents/Children Aboard
ticket: Ticket Number
fare: Passenger Fare
cabin: Cabin
embarked: Port of Embarkation (C = Cherbourg; Q = Queenstown; S = Southampton)

Lecture du fichier
Récupérer le fichier titanic.csv et le mettre dans le répertoire Dataset.
Intégrer le contenu de ce fichier dans un dataframe pandas.

In [1]:

```
import pandas as pd

#attention le séparateur est une tabulation
df=pd.read_csv('Dataset/titanic.csv',
               sep='\t')
df

```

Out[1]:

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabi
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN
5	6	0	3	Moran, Mr.	male	NaN	0	0	330877	8.4583	NaN

Analyse des données

L'objectif dans un premier temps est de se familiariser avec pandas pour obtenir des informations sur le jeu de données.

Pandas

Afficher la taille du dataframe, les six premières lignes, les trois dernières lignes et 5 lignes au hasard du dataframe.

In [2]:

```
print ("taille du dataframe : \n")
display(df.shape)

print ("Six premières lignes du dataframe : \n")
display(df.head(6))
print ("\n Trois dernières lignes du dataframe : \n")
display(df.tail(3))
print ("\n Cinq lignes au hasard du dataframe : \n")
display(df.sample(5))
```

```
taille du dataframe :
```

(156, 12)

Six premières lignes du dataframe :

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500
5	6	0	3	Moran, Mr. James	male	NaN	0	0	330877	8.4583

Trois dernières lignes du dataframe :

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Ca
153	154	0	3	van Billiard, Mr. Austin Blyler	male	40.5	0	2	A/5. 851	14.5000	N
154	155	0	3	Olsen, Mr. Ole Martin	male	NaN	0	0	Fa 265302	7.3125	N
155	156	0	1	Williams, Mr. Charles Duane	male	51.0	0	1	PC 17597	61.3792	N

Cinq lignes au hasard du dataframe :

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare
110	111	0	1	Porter, Mr. Walter Chamberlain	male	47.0	0	0	110465	52.0000

6	7	0	1	McCarthy, Mr. Timothy J	male	54.0	0	0	17463	51.8625
113	114	0	3	Jussila, Miss. Katriina	female	20.0	1	0	4136	9.825(
119	120	0	3	Andersson, Miss. Ellis Anna Maria	female	2.0	4	2	347082	31.275(
56	57	1	2	Rugg, Miss. Emily	female	21.0	0	0	C.A. 31026	10.500(

Donner les informations sur le cinquième passager

In [3]:

```
# attention là si on passe par
#le numéro d'index donc il faut utilser iloc
# la numérotation des index commence à zéro
print (df.iloc[4])
# ou en passant par les colonnes
print (df.loc[4])
```

```
PassengerId                      5
Survived                         0
Pclass                           3
Name           Allen, Mr. William Henry
Sex                           male
Age                             35
SibSp                            0
Parch                            0
Ticket                      373450
Fare                          8.05
Cabin                          NaN
Embarked                         S
Name: 4, dtype: object
PassengerId                      5
Survived                         0
Pclass                           3
Name           Allen, Mr. William Henry
Sex                           male
Age                             35
SibSp                            0
Parch                            0
Ticket                      373450
Fare                          8.05
Cabin                          NaN
Embarked                         S
Name: 4, dtype: object
```

Donner toutes les informations sur les passagers compris entre les lignes 10 et 16

In [4]:

```
1  display(df.iloc[10:17])
```

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare
10	11	1	3	Sandstrom, Miss. Marguerite Rut	female	4.0	1	1	PP 9549	16.700
11	12	1	1	Bonnell, Miss. Elizabeth	female	58.0	0	0	113783	26.550
12	13	0	3	Saundercock, Mr. William Henry	male	20.0	0	0	A/5. 2151	8.050
13	14	0	3	Andersson, Mr. Anders Johan	male	39.0	1	5	347082	31.275
14	15	0	3	Vestrom, Miss. Hulda Amanda Adolfina	female	14.0	0	0	350406	7.854
15	16	1	2	Hewlett, Mrs. (Mary D Kingcome)	female	55.0	0	0	248706	16.000
16	17	0	3	Rice, Master. Eugene	male	2.0	4	1	382652	29.125

Donner les informations sur le passager dont le numéro (PassengerId) est 5

In [5]:

```
1  print (df[df['PassengerId']==5])
```

```
   PassengerId  Survived  Pclass                      Name   Sex   A
ge  SibSp  \
4            5         0       3  Allen, Mr. William Henry  male  35
.0      0

   Parch  Ticket  Fare Cabin Embarked
4      0  373450  8.05   NaN        S
```

Indiquer les différentes informations associées aux colonnes (Nom des colonnes, type de la colonne, place prise par le dataframe, etc).

In [6]:

```
1  df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 156 entries, 0 to 155
Data columns (total 12 columns):
PassengerId    156 non-null int64
Survived       156 non-null int64
Pclass         156 non-null int64
Name           156 non-null object
Sex            156 non-null object
Age            126 non-null float64
SibSp          156 non-null int64
Parch          156 non-null int64
Ticket         156 non-null object
Fare           156 non-null float64
Cabin          31 non-null object
Embarked       155 non-null object
dtypes: float64(2), int64(5), object(5)
memory usage: 14.7+ KB
```

Quel est le type de la colonne *Name* ?

In [7]:

```
1  print (df['Name'].dtype)
```

```
object
```

Donner des statistiques de base du dataframe et préciser pourquoi Name n'apparait pas dans le résultat.

In [8]:

```
1  df.describe()
2  # describe ne considère que des attributs
3  #numériques. Name est un objet (un str)
```

Out[8]:

	PassengerId	Survived	Pclass	Age	SibSp	Parch	Fare
count	156.000000	156.000000	156.000000	126.000000	156.000000	156.000000	156.000000
mean	78.500000	0.346154	2.423077	28.141508	0.615385	0.397436	28.109587
std	45.177428	0.477275	0.795459	14.613880	1.056235	0.870146	39.401047
min	1.000000	0.000000	1.000000	0.830000	0.000000	0.000000	6.750000
25%	39.750000	0.000000	2.000000	19.000000	0.000000	0.000000	8.003150
50%	78.500000	0.000000	3.000000	26.000000	0.000000	0.000000	14.454200
75%	117.250000	1.000000	3.000000	35.000000	1.000000	0.000000	30.371850
max	156.000000	1.000000	3.000000	71.000000	5.000000	5.000000	263.000000

Donner le nombre de survivants? Indication il faut compter combien de PassagerId ont survécu.

In [9]:

```
nb=df[df['Survived']==1]
print ("Nombre de survivants : ",
       nb['PassengerId'].count())
```

```
Nombre de survivants :  54
```

Donner par categorie male/female le nombre de personnes qui ont ou n'ont pas survécu. Indication utilisation d'un groupby.

In [10]:

```
g=df.groupby(['Sex','Survived'])
print (g['PassengerId'].count())
```

```
Sex     Survived
female  0           16
        1           40
male    0           86
        1           14
Name: PassengerId, dtype: int64
```

Donner par categorie de classe le nombre de personnes qui ont ou n'ont pas survécu.

In [11]:

```
g=df.groupby(['Pclass','Survived'])
print (g['PassengerId'].count())
```

```
Pclass  Survived
1       0           18
        1           12
2       0           16
        1           14
3       0           68
        1           28
Name: PassengerId, dtype: int64
```

Donner par categorie de classe et de sexe le nombre de personnes qui ont ou n'ont pas survécu.

In [12]:

```
g=df.groupby(['Pclass','Sex','Survived'])
print (g['PassengerId'].count())
```

```
Pclass  Sex     Survived
1       female  1             9
        male    0            18
                1             3
2       female  0             1
                1            11
        male    0            15
                1             3
3       female  0            15
                1            20
        male    0            53
                1             8
Name: PassengerId, dtype: int64
```

Donner la liste des femmes qui ont survécu et dont l'age est supérieure à 30

In [13]:

```
print(df.loc[(df["Sex"]=="female") &
             (df["Survived"]==1)&
             (df["Age"]>30)] )

#ou bien
print ("\n autre version sans loc:\n")
print (df[(df["Sex"]=="female") &
          (df["Survived"]==1)&
          (df["Age"]>30)] )
```

```
     PassengerId  Survived  Pclass  \
1              2         1       1
3              4         1       1
11            12         1       1
15            16         1       2
25            26         1       3
52            53         1       1
61            62         1       1
85            86         1       3
98            99         1       2
123          124         1       2

                                                  Name     Sex   Age
SibSp  \
1    Cumings, Mrs. John Bradley (Florence Briggs Th...  female  38.0
1
3         Futrelle, Mrs. Jacques Heath (Lily May Peel)  female  35.0
1
11                             Bonnell, Miss. Elizabeth  female  58.0
0
15                    Hewlett, Mrs. (Mary D Kingcome)    female  55.0
0
25   Asplund, Mrs. Carl Oscar (Selma Augusta Emilia...  female  38.0
```

1
52 Harper, Mrs. Henry Sleeper (Myna Haxtun) female 49.0
1
61 Icard, Miss. Amelie female 38.0
0
85 Backstrom, Mrs. Karl Alfred (Maria Mathilda Gu... female 33.0
3
98 Doling, Mrs. John T (Ada Julia Bone) female 34.0
0
123 Webber, Miss. Susan female 32.5
0

	Parch	Ticket	Fare	Cabin	Embarked
1	0	PC 17599	71.2833	C85	C
3	0	113803	53.1000	C123	S
11	0	113783	26.5500	C103	S
15	0	248706	16.0000	NaN	S
25	5	347077	31.3875	NaN	S
52	0	PC 17572	76.7292	D33	C
61	0	113572	80.0000	B28	NaN
85	0	3101278	15.8500	NaN	S
98	1	231919	23.0000	NaN	S
123	0	27267	13.0000	E101	S

autre version sans loc:

	PassengerId	Survived	Pclass	\
1	2	1	1	
3	4	1	1	
11	12	1	1	
15	16	1	2	
25	26	1	3	
52	53	1	1	
61	62	1	1	
85	86	1	3	
98	99	1	2	
123	124	1	2	

	Name	Sex	Age
SibSp \			
1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0
1			
3	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0
1			
11	Bonnell, Miss. Elizabeth	female	58.0
0			
15	Hewlett, Mrs. (Mary D Kingcome)	female	55.0
0			
25	Asplund, Mrs. Carl Oscar (Selma Augusta Emilia...	female	38.0
1			
52	Harper, Mrs. Henry Sleeper (Myna Haxtun)	female	49.0
1			
61	Icard, Miss. Amelie	female	38.0
0			
85	Backstrom, Mrs. Karl Alfred (Maria Mathilda Gu...	female	33.0
3			
98	Doling, Mrs. John T (Ada Julia Bone)	female	34.0

```
0
123                                Webber, Miss. Susan  female  32.5
0

     Parch    Ticket     Fare Cabin Embarked
1        0  PC 17599  71.2833   C85        C
3        0    113803  53.1000  C123        S
11       0    113783  26.5500  C103        S
15       0    248706  16.0000   NaN        S
25       5    347077  31.3875   NaN        S
52       0  PC 17572  76.7292   D33        C
61       0    113572  80.0000   B28      NaN
85       0   3101278  15.8500   NaN        S
98       1    231919  23.0000   NaN        S
123      0     27267  13.0000  E101        S
```

Donner l'age max, min et moyen des personnes qui ont survécu

In [14]:

```
df2=df[df['Survived']==1]
print ("Age max : ",df2['Age'].max())
print ("\nAge min : ",df2['Age'].min())
print ("\nAge moyen : ",df2['Age'].mean())


# ou bien
print ("\nAge moyen : ",
       (df[df['Survived']==1])['Age'].mean())
```

```
Age max :  58.0

Age min :  0.83

Age moyen :  25.61780487804878

Age moyen :  25.61780487804878
```

Visualisation

L'objectif est ici de visualiser quelques informations à l'aide de seaborn pour mettre en évidence les premières analyses précédentes.

Dans un premier temps à l'aide de seaborn et de la fonction countplot afficher le nombre de survivants et de non survivants

In [15]:

```
import seaborn as sns
import matplotlib.pyplot as plt

sns.countplot(x='Survived', data=df)
```

Out[15]:

```
<matplotlib.axes._subplots.AxesSubplot at 0x114104ef0>
```

Afficher le nombre de catégorie male/female (attribut Sex) avec countplot.

In [16]:

```
sns.countplot(x='Sex', data=df)
```

Out[16]:

```
<matplotlib.axes._subplots.AxesSubplot at 0x106613710>
```

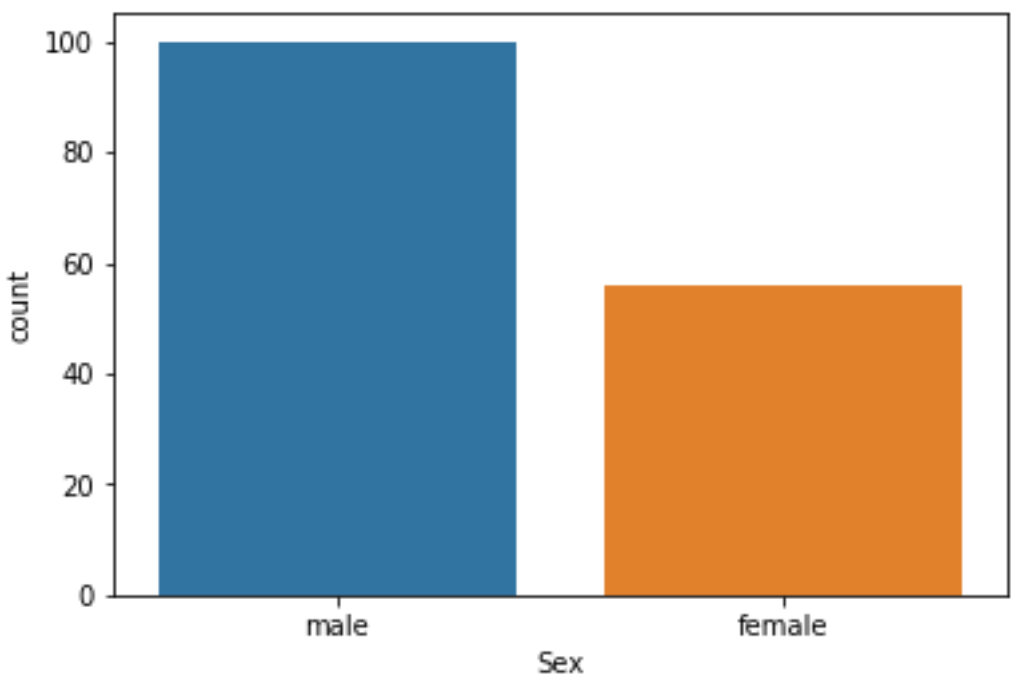

La commande suivante affiche les survivants ou non en fonction du sexe.

sns.factorplot(x='Survived', col='Sex', kind='count', data=df)

Essayer de l'utiliser et faire de même par rapport aux attributs Pclass et Embarked. Que pouvez vous déduire dans un premier temps sur les survivants ou non.

In [17]:

```
sns.factorplot(x='Survived',
               col='Sex',
               kind='count', data=df)

sns.factorplot(x='Survived',
               col='Pclass',
               kind='count', data=df)


sns.factorplot(x='Survived',
```

```
                  col='Embarked',
                  kind='count', data=df)

#il y moins de survivants homme,
#pas terrible la troisième classe,
#il valait mieux ne pas embarquer à Southampton

```

Out[17]:

```
<seaborn.axisgrid.FacetGrid at 0x1143f3240>
```

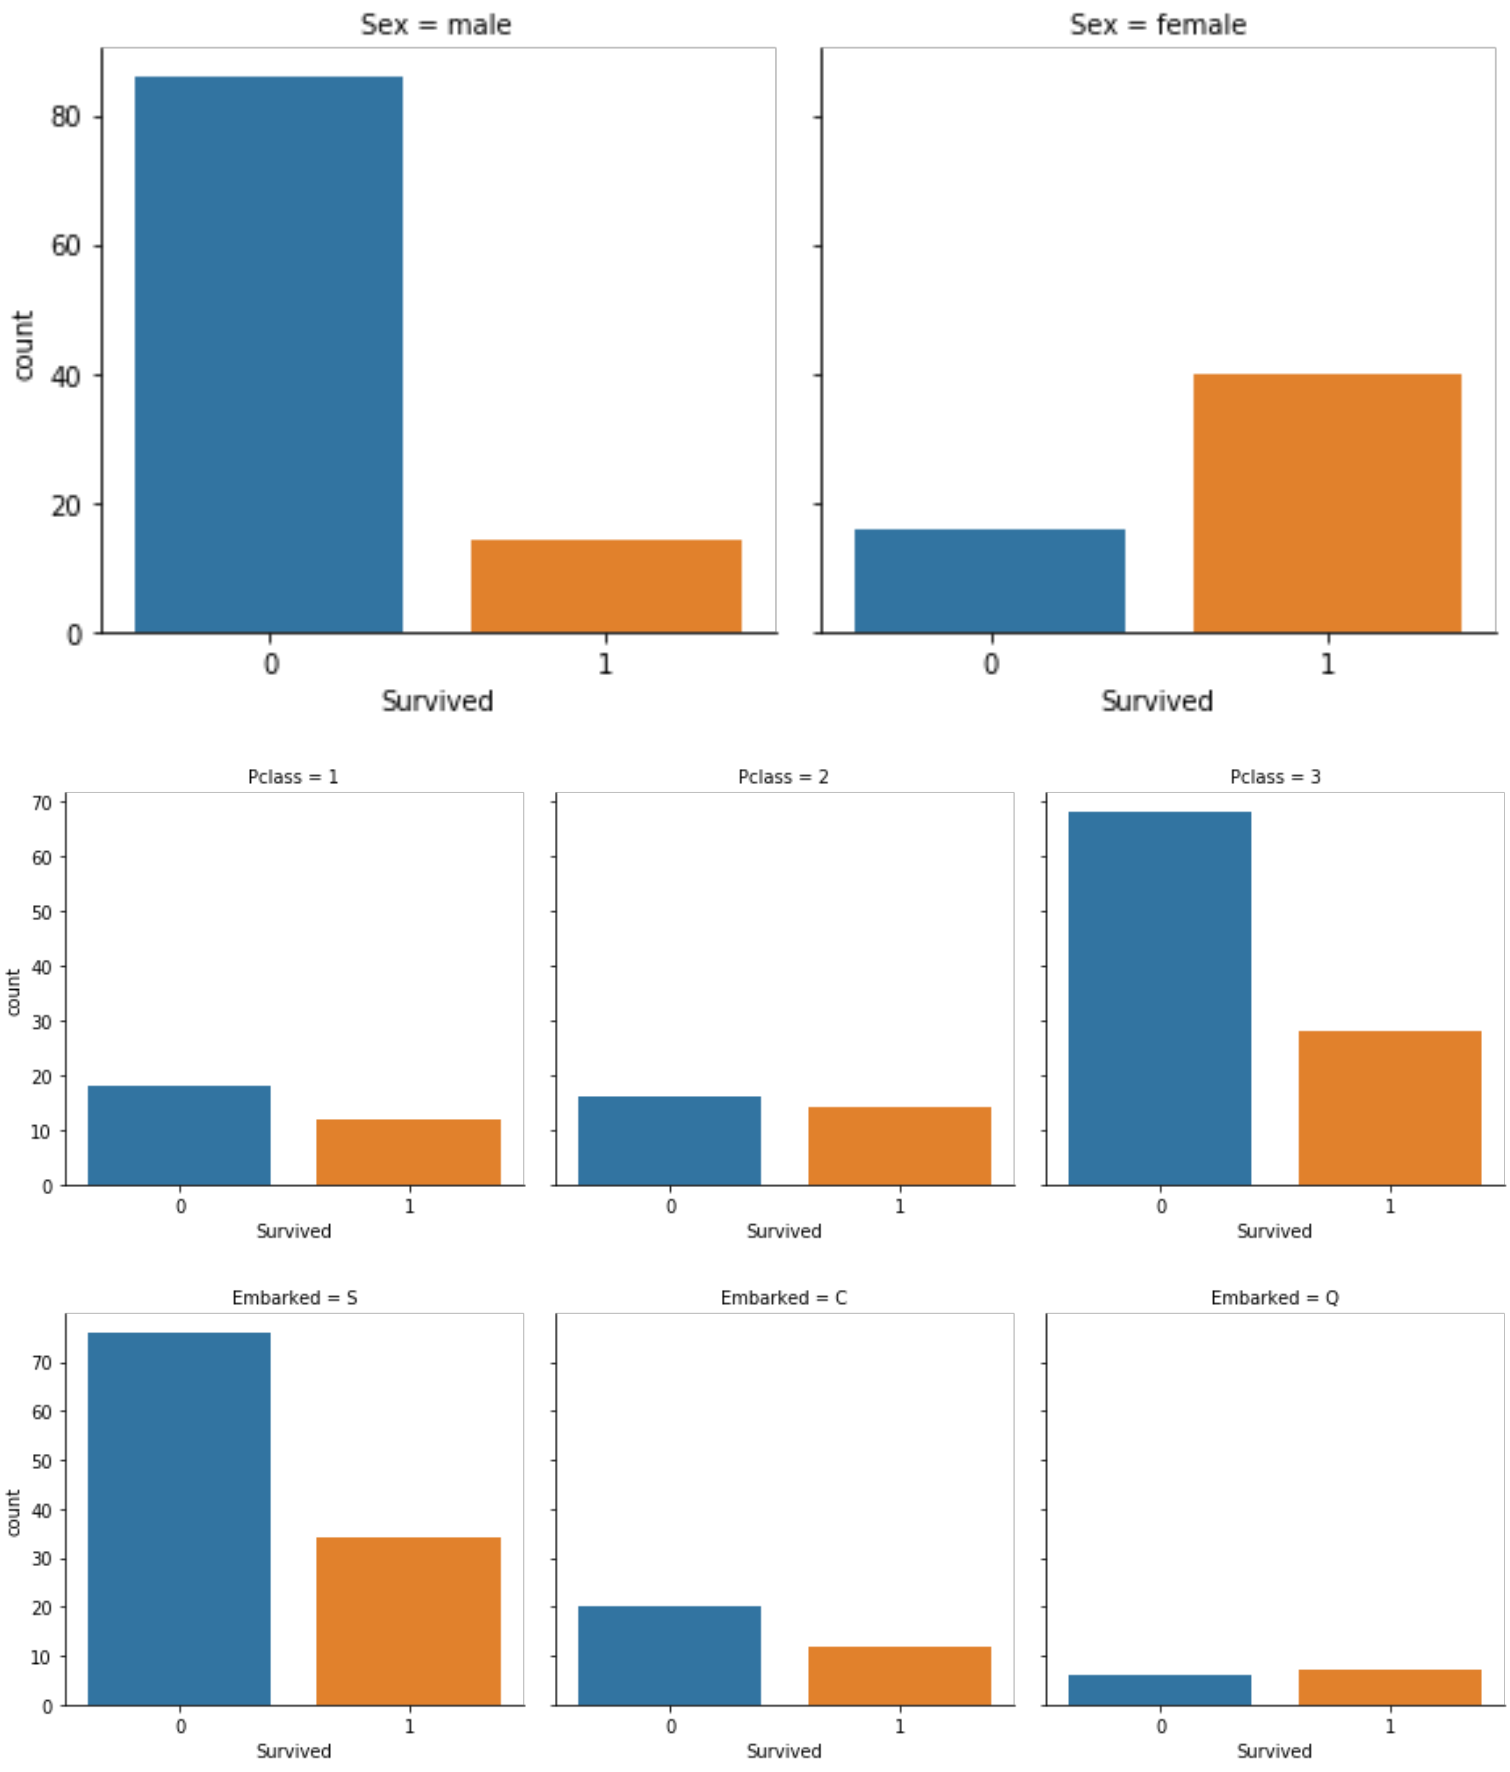

Un peu plus loin sur l'analyse ...

Le code suivant permet de connaître la répartition par sexe et par classe :

```
g = sns.factorplot('Pclass', data=df, hue='Sex', kind='count')
g.set_xlabels('Class')
```

Exécuter le code. Que constatez vous ? Faire la même chose pour Embarked

In [18]:

```
g = sns.factorplot('Pclass',
                   data=df,
                   hue='Sex',
                   kind='count')
g.set_xlabels('Class')

# plus de male en classe 3

g = sns.factorplot('Embarked',
                   data=df, hue='Sex',
                   kind='count')
g.set_xlabels('Embarked')

# plus de male de Southampton
```

Out[18]:

```
<seaborn.axisgrid.FacetGrid at 0x1144a0da0>
```

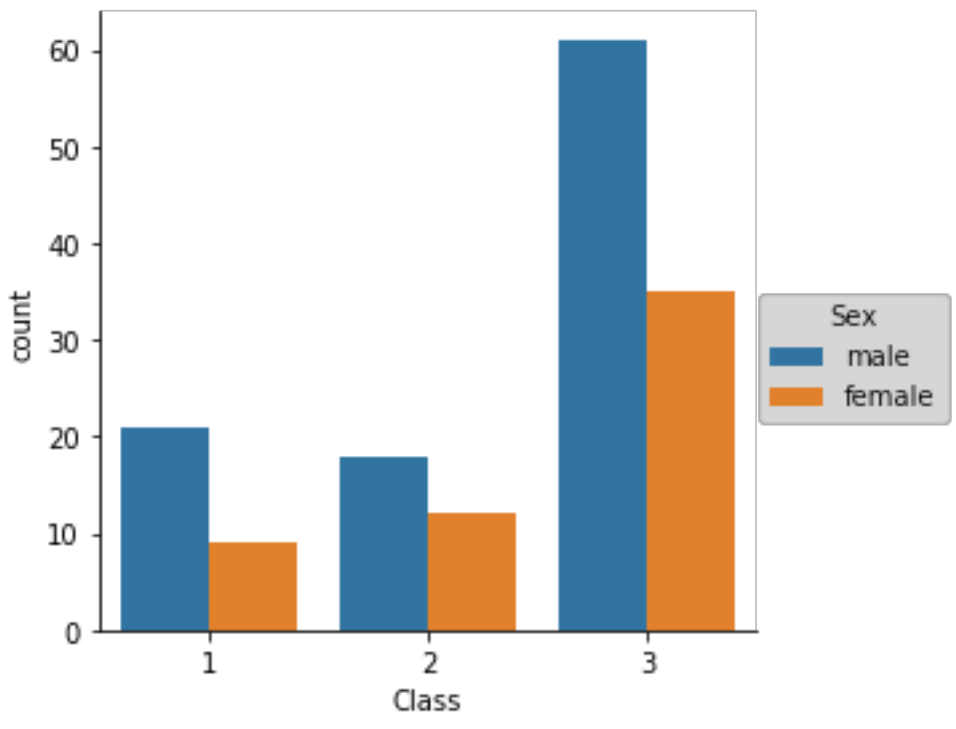

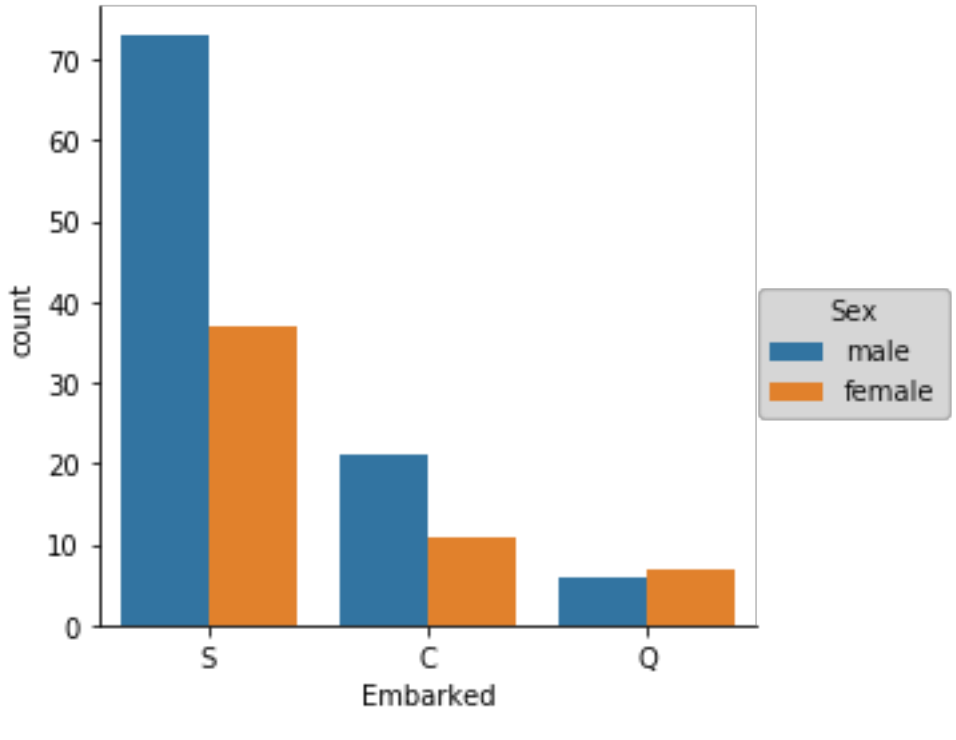

A votre factor plot ajouter col='Survived' comme paramètre pour voir la répartition par rapport au sexe des passagers. Faites de même par rapport à Embarked.

In [19]:

```
sns.factorplot('Pclass',
               data=df,
               kind='count',
               hue='Sex',
               col='Survived')


sns.factorplot('Embarked',
               data=df,
               hue='Sex',
               kind='count',
               col='Survived')

```

Out[19]:

```
<seaborn.axisgrid.FacetGrid at 0x1148bad30>
```

Créer la fonction suivante qui permet de créer des catégories en fonction de l'age des personnes. Ajouter dans df une colonne 'Person' qui contient la valeur de cet attribut.

```
def male_female_age(passenger):
     age, sex = passenger
     if age < 5:
         return 'Baby'
     if age >= 5 and age < 12:
         return 'Child'
     if age >= 12 and age < 18:
         return 'Teneeger'
     if age >=18 and age < 35:
         return 'Young Adult'
     if age >= 35 and age < 60:
         return 'Adult'
     if age >= 60:
         return 'Senior'
     else:
         return sex

Rappel : pour appliquer une fonction à une colonne
    df[['Age', 'Sex']].apply(male_female_child, axis=1)
```

In [20]:

```
def male_female_age(passenger):
    age, sex = passenger
    if age < 5:
        return 'Baby'
    if age >= 5 and age < 12:
        return 'Child'
    if age >= 12 and age < 18:
        return 'Teneeger'
    if age >=18 and age < 35:
        return 'Young Adult'
    if age >= 35 and age < 60:
        return 'Adult'
    if age >= 60:
        return 'Senior'
    else:
        return sex
```

In [21]:

```
df['Person']=df[['Age','Sex']].apply(male_female_age,
                                     axis=1)
df.head()
```

Out[21]:

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500

Sur vos factorplot précédents remplacer hue='Sex' par hue='Person' et relancer les. Que constatez vous ?

In [22]:

```
sns.factorplot('Pclass',
               data=df,
               kind='count',
               hue='Person',
               col='Survived')


sns.factorplot('Embarked',
               data=df,
               hue='Person',
               kind='count',
               col='Survived')

#les enfants de troisième classe !
```

Out[22]:

```
<seaborn.axisgrid.FacetGrid at 0x115158710>
```

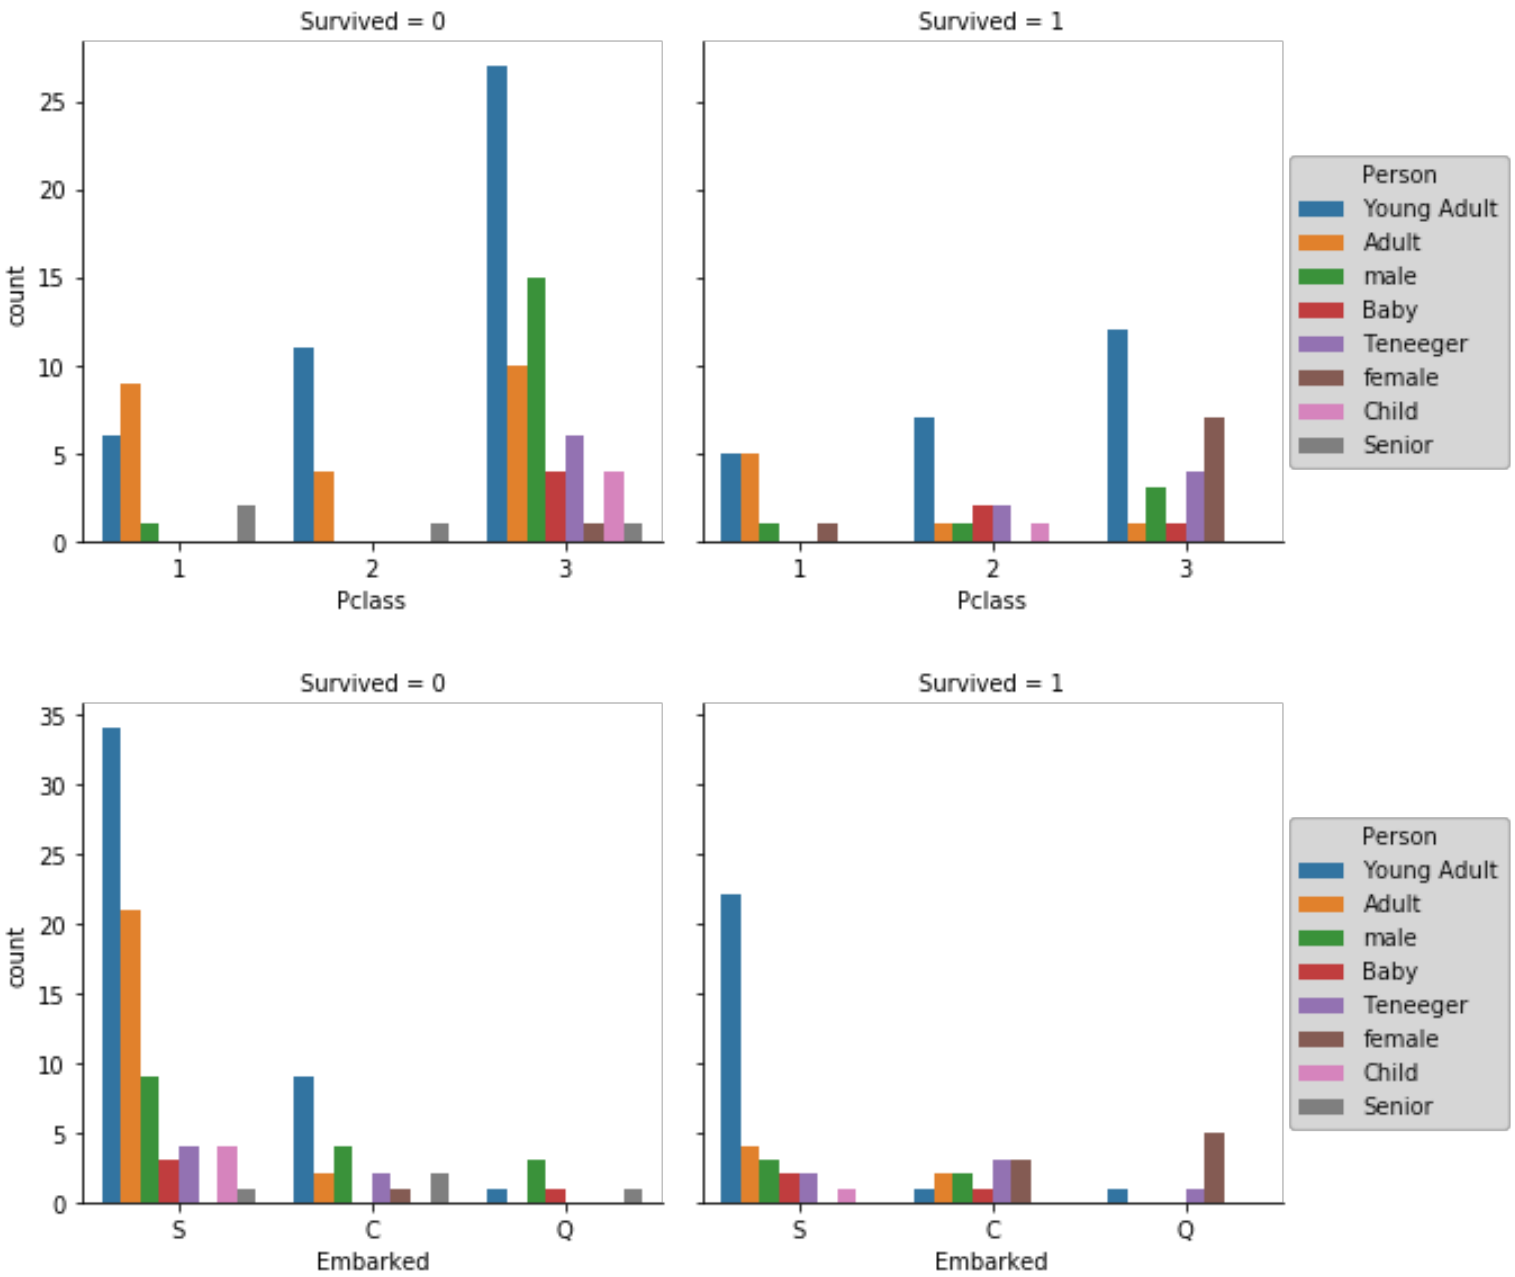

Enfin regarder la répartition pour les embarquements et les classes.

In [23]:

```
sns.factorplot('Pclass', data=df,
               kind='count',
               hue='Person', col='Embarked')

#Les troisièmes classes ont majoritairement embarquer à Southtampton
```

Out[23]:

```
<seaborn.axisgrid.FacetGrid at 0x11109dba8>
```

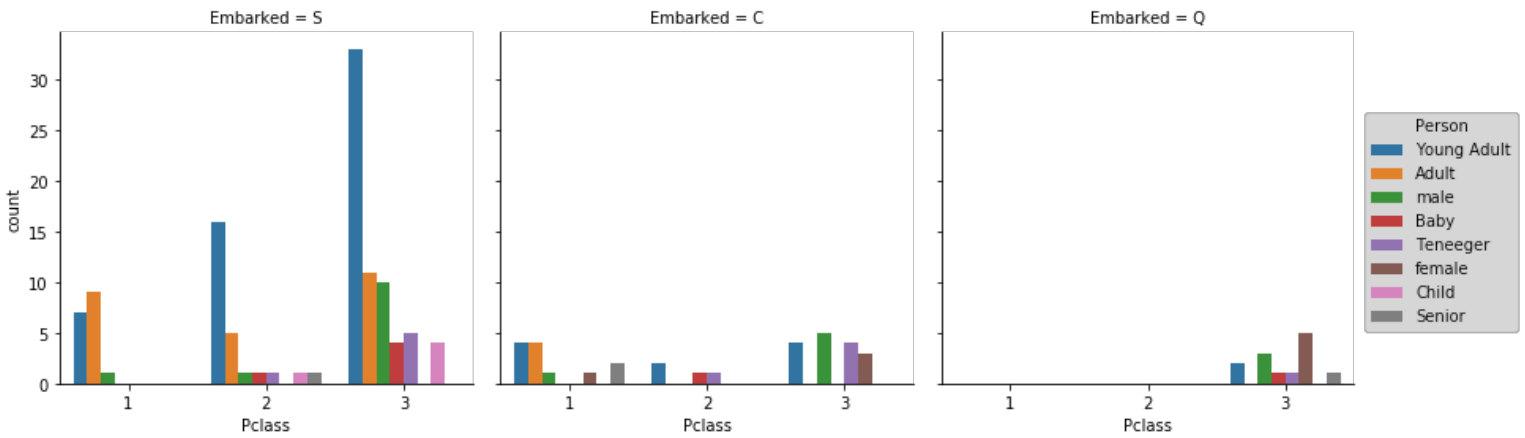

Quelques informations sur la distribution. A l'aide de displot afficher la distribution de Pclass et de Fare.

In [24]:

```
1  pclass_dist=sns.distplot(df["Pclass"])
2  pclass_dist.set_title("Distribution des classes")
3
4
```

```
/Users/pascalponcelet/Desktop/Sicki-learn/Tools/tools/lib/python3.6/
site-packages/matplotlib/axes/_axes.py:6521: MatplotlibDeprecationWa
rning:
The 'normed' kwarg was deprecated in Matplotlib 2.1 and will be remo
ved in 3.1. Use 'density' instead.
  alternative="'density'", removal="3.1")
```

Out[24]:

```
Text(0.5, 1.0, 'Distribution des classes')
```

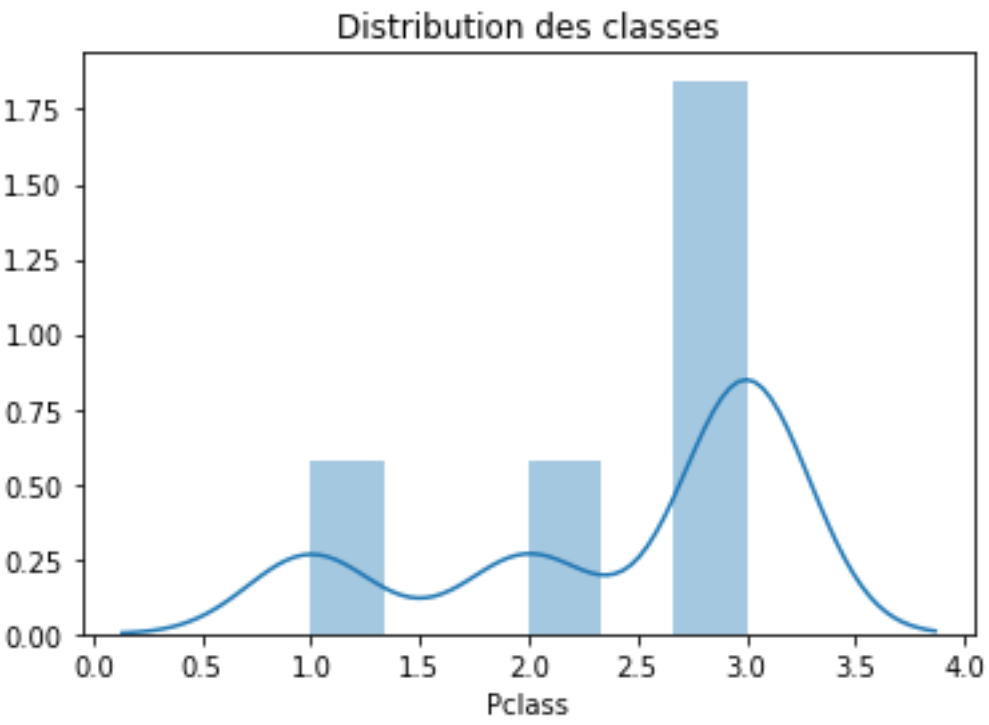

In [25]:

```
1  fare_dist=sns.distplot(df["Fare"])
2  fare_dist.set_title("Distribution des tarifs")
3
4
```

```
/Users/pascalponcelet/Desktop/Sicki-learn/Tools/tools/lib/python3.6/
site-packages/matplotlib/axes/_axes.py:6521: MatplotlibDeprecationWa
rning:
The 'normed' kwarg was deprecated in Matplotlib 2.1 and will be remo
ved in 3.1. Use 'density' instead.
  alternative="'density'", removal="3.1")
```

Out[25]:

```
Text(0.5, 1.0, 'Distribution des tarifs')
```

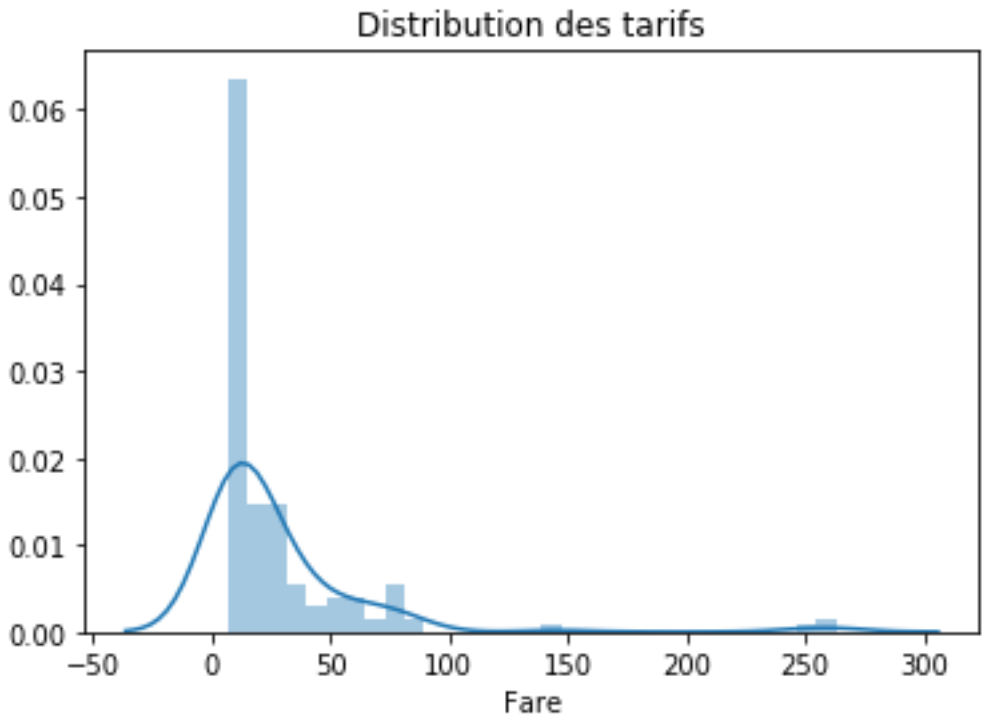

Afficher à l'aide de la fonction boxplot une boîte à moustache pour Pclass et Fare.

In [26]:

```
1
2
```
```
sns.boxplot(x=df["Pclass"], orient='v')

```

Out[26]:

```
<matplotlib.axes._subplots.AxesSubplot at 0x1141fa240>
```

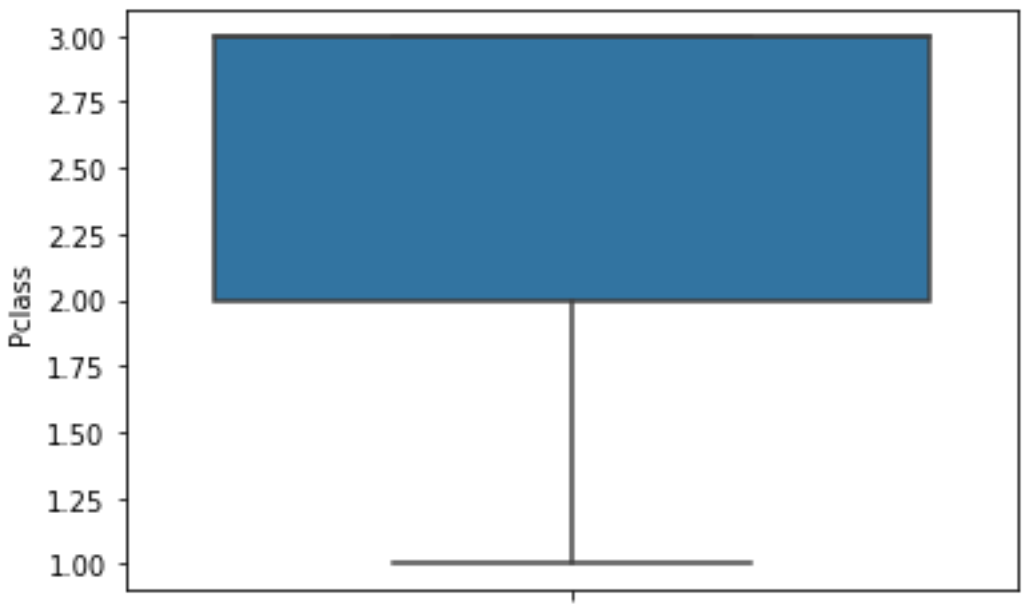

In [27]:

```
1
```
```
sns.boxplot(x=df["Fare"], orient='v')
```

Out[27]:

```
<matplotlib.axes._subplots.AxesSubplot at 0x114debe10>
```

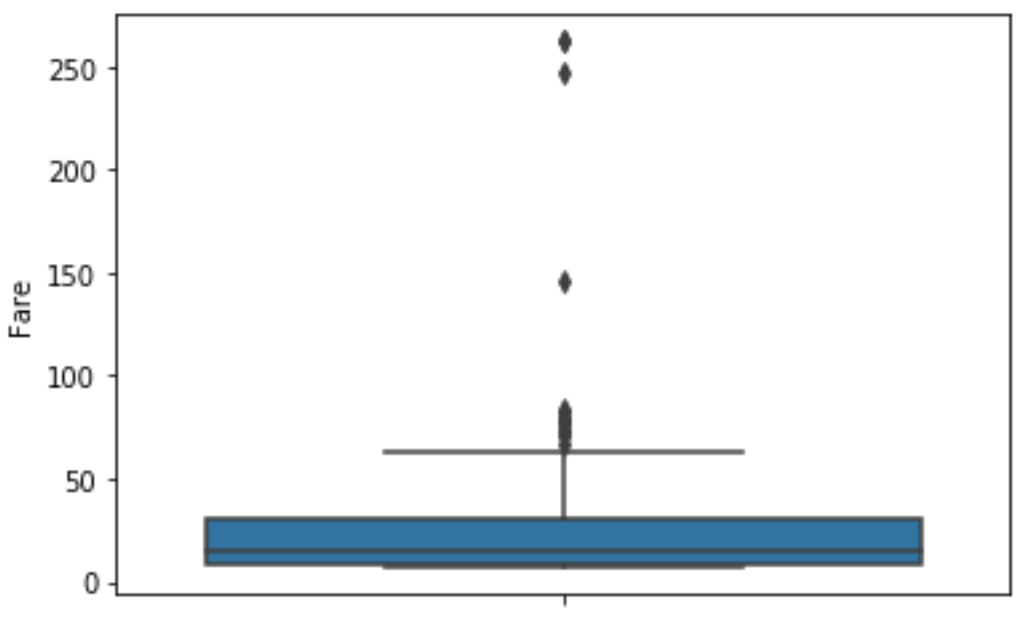

Faire les mêmes opérations à l'aide de la fonction violinplot.
Rappel : elle offre les mêmes fonctionnalités que les boîtes à moustache mais en plus offre des informations sur une estimation de la densité.

In [28]:

```
1  sns.violinplot(x=df["Fare"], orient='v')
```

Out[28]:

```
<matplotlib.axes._subplots.AxesSubplot at 0x1153258d0>
```

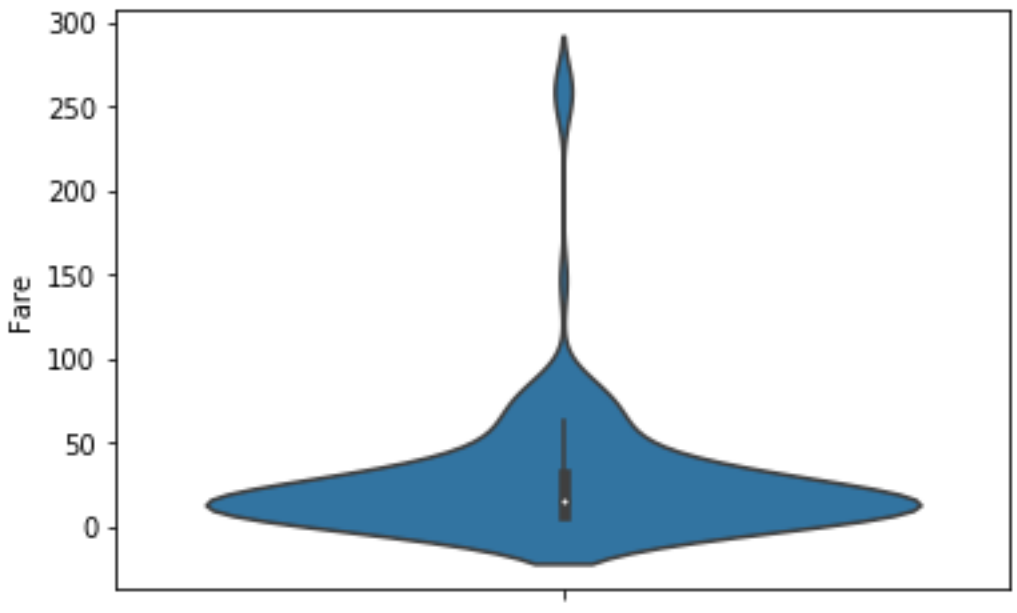

In [29]:

```
1  sns.violinplot(x=df["Pclass"], orient='v')
```

Out[29]:

```
<matplotlib.axes._subplots.AxesSubplot at 0x114bb2a90>
```

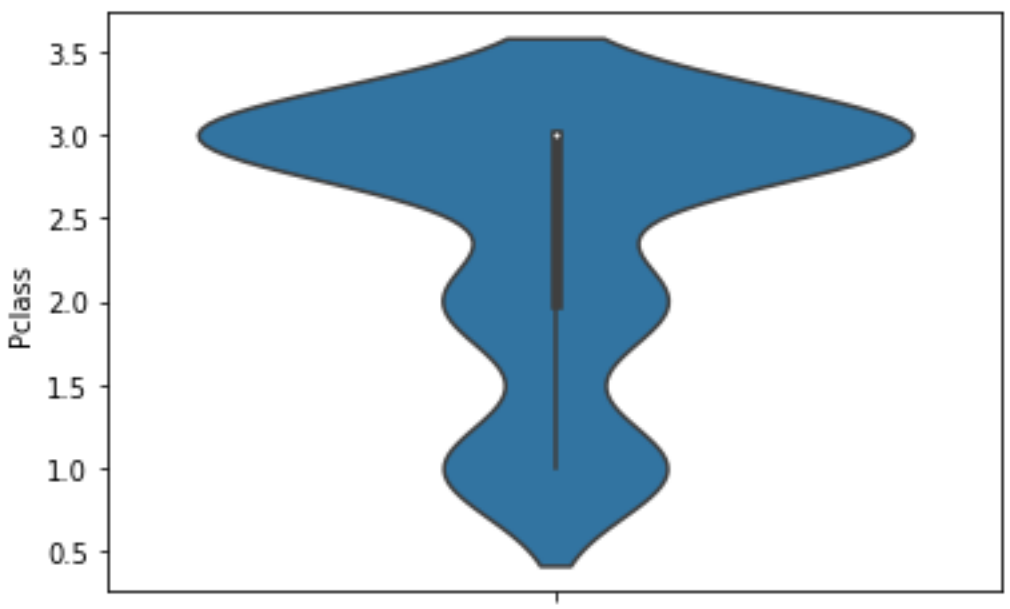

A présent, considérons l'age des personnes. A l'aide de displot afficher l'histogramme de distribution des ages avec le code suivant :

age_dist=sns.distplot(df["Age"])
age_dist.set_title("Distribution des ages")

Que se passe-t'il ?

Une erreur est levée "cannot convert float NaN to integer". NaN indique la présence de valeurs manquantes dans le jeu de données.

Ingénierie des données

Traitement des valeurs manquantes

Créer un nouveau dataframe df2 (pour créer un dataframe sans modifier le dataframe initial il faut en faire une copie : df2=df.copy()).

In [30]:

```
df2=df.copy()
```

Donner la liste des colonnes pour lesquelles il y a des valeurs manquantes. Pour tester si une valeur est manquante, il est possible pour un dataframe d'utiliser pour une colonne la fonction isnull(). Attention celle-ci retourne un dataframe. Elle doit être suivie par any() pour avoir un booléen :

```
df ['colonne'].isnull().any()
```

In [31]:

```
for col in df2.columns:
    valeur=False
    valeur = df2[col].isnull().any()
    if valeur:
        print (col)
```

```
Age
Cabin
Embarked
```

Il est également possible d'afficher l'ensemble des données qui contiennent des valeurs NaN de la manière suivante :

sns.heatmap(df.isnull(), cbar=False)

In [32]:

```
1  sns.heatmap(df2.isnull(), cbar=False)
```

Out[32]:

```
<matplotlib.axes._subplots.AxesSubplot at 0x108009390>
```

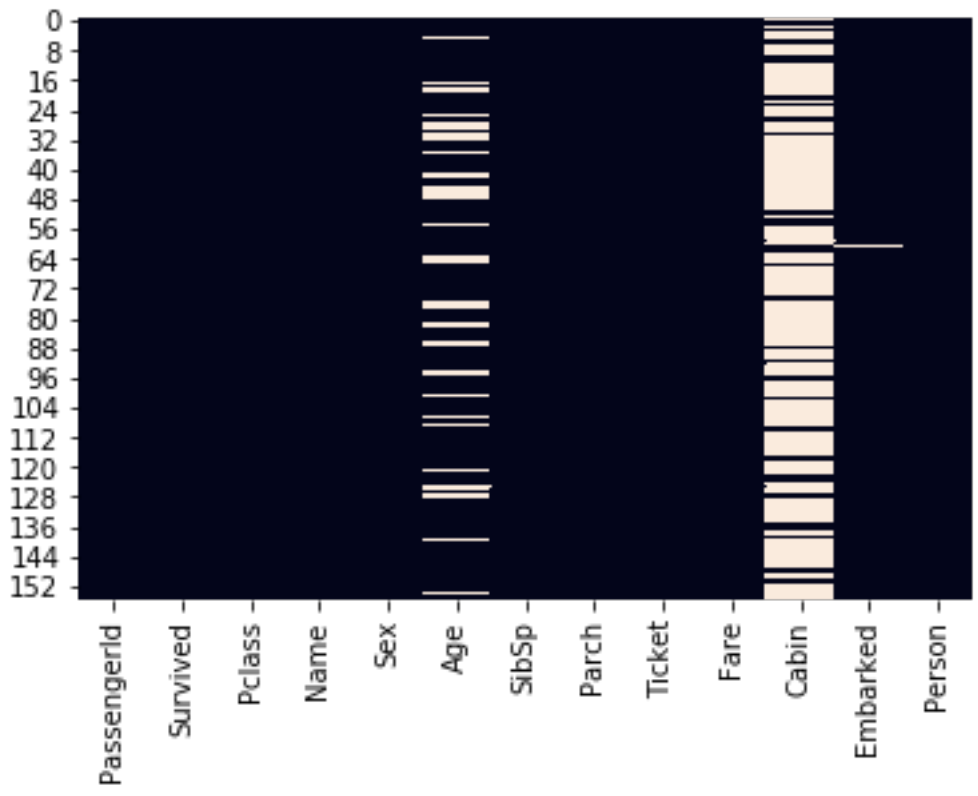

Afficher le nombre de valeurs nulles Embarked, Cabin et Sex.

In [33]:

```
1
2  print ("Nombre de valeurs nulles pour Embarked : \n",
3         df2['Embarked'].isnull().value_counts() )
4  print ("\nNombre de valeurs nulles pour Cabin : \n",
5         df2['Cabin'].isnull().value_counts() )
6  print ("\nNombre de valeurs nulles pour Sex : \n",
7         df2['Sex'].isnull().value_counts() )
8
9
```

```
Nombre de valeurs nulles pour Embarked :
 False    155
True       1
Name: Embarked, dtype: int64

Nombre de valeurs nulles pour Cabin :
 True     125
False     31
Name: Cabin, dtype: int64

Nombre de valeurs nulles pour Sex :
 False    156
Name: Sex, dtype: int64
```

Remplacer les valeurs nulles de l'age par la moyenne des ages des passagers. Penser à vérifier que la transformation a bien été effectuée.

In [34]:

```
print ("Pour vérifier : \n")
print (df2.iloc[5])
moyenne_age = df2['Age'].mean()
print ("\n Moyenne age : \n", moyenne_age)
df2['Age']=df2['Age'].fillna(df2['Age'].mean())

print ("\nPour vérifier : \n",df2.iloc[5])


```

```
Pour vérifier :

PassengerId                    6
Survived                       0
Pclass                         3
Name             Moran, Mr. James
Sex                          male
Age                           NaN
SibSp                           0
Parch                           0
Ticket                     330877
Fare                       8.4583
Cabin                         NaN
Embarked                        Q
Person                       male
Name: 5, dtype: object

 Moyenne age :
 28.141507936507935

Pour vérifier :
 PassengerId                    6
Survived                        0
Pclass                          3
Name             Moran, Mr. James
Sex                          male
Age                       28.1415
SibSp                           0
Parch                           0
Ticket                     330877
Fare                       8.4583
Cabin                         NaN
Embarked                        Q
Person                       male
Name: 5, dtype: object
```

Supprimer tous les enregistrements qui contiennent encore une valeur nulle.

In [35]:

```
print ("Pour vérification : \n")
print ("Nombre de valeurs nulles pour Embarked : \n",
       df2['Embarked'].isnull().value_counts() )
print ("\nNombre de valeurs nulles pour Cabin : \n",
       df2['Cabin'].isnull().value_counts() )

df2=df2.dropna()
print ("\nNombre de valeurs nulles pour Embarked : \n",
       df2['Embarked'].isnull().value_counts() )
print ("\nNombre de valeurs nulles pour Cabin : \n",
       df2['Cabin'].isnull().value_counts() )


```

```
Pour vérification :

Nombre de valeurs nulles pour Embarked :
 False    155
True       1
Name: Embarked, dtype: int64

Nombre de valeurs nulles pour Cabin :
 True     125
False     31
Name: Cabin, dtype: int64

Nombre de valeurs nulles pour Embarked :
 False    30
Name: Embarked, dtype: int64

Nombre de valeurs nulles pour Cabin :
 False    30
Name: Cabin, dtype: int64
```

Utiliser sns.heatmap(df.isnull(), cbar=False) sur votre dataframe pour vérifier qu'il n'y a plus de valeurs nulles.

In [36]:

```
1
2
3
```

```
sns.heatmap(df2.isnull(), cbar=False)
```

Out[36]:

```
<matplotlib.axes._subplots.AxesSubplot at 0x11638cc18>
```

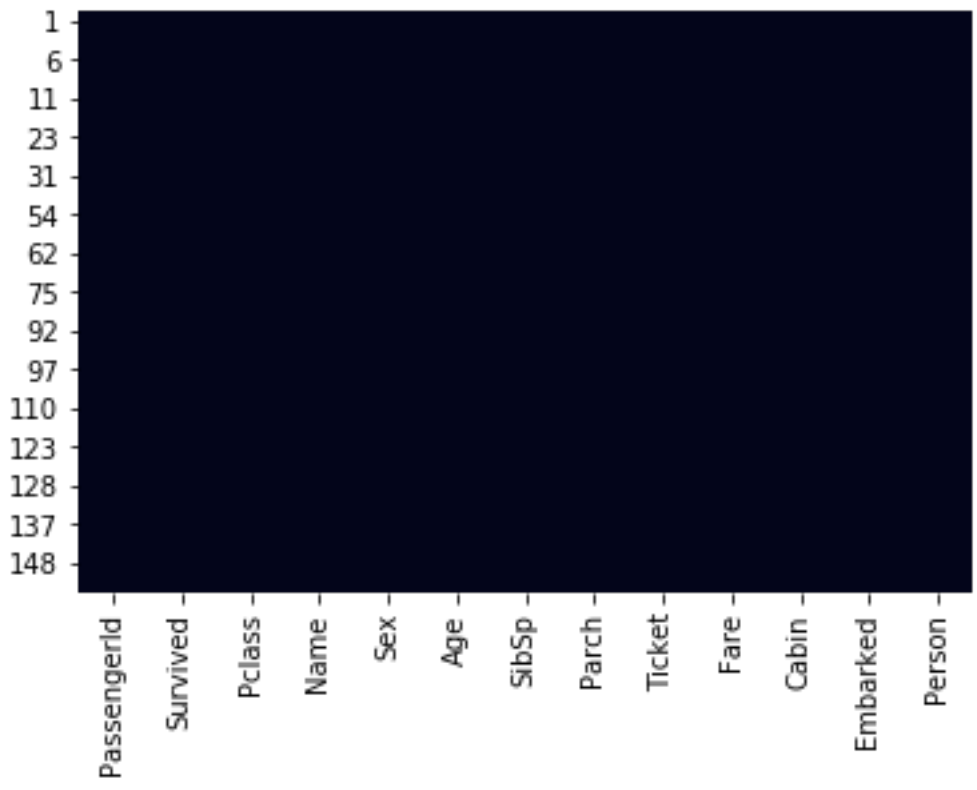

Quelle est la taille de votre dataframa à présent ? Comparer le à la taille initiale.

In [37]:

```
1
```

```
print(df2.shape)
```

```
(30, 13)
```

En fait en supprimant les valeurs manquantes de cabines de trop nombreux enregristrements ont été effacés. Nous pouvons constater qu'il y a beaucoup de valeurs manquantes pour Cabin et que dans tous les cas elle ne va donc pas pouvoir aider à faire de la classification.

Créer un nouveau dataframe df3=df.copy().
Remplacer la valeur d'age par la médiane.
Par simplification, supprimer la colonne Cabin.
Rappel : pour supprimer une colonne df.drop('Nom colonne',1). Effacer les autres valeurs manquantes.
Enfin, supprimer toutes les valeurs manquantes.

Vérifier à l'aide de heatmap que votre jeu de données n'a plus de valeurs manquantes. Indiquer la taille du jeu de données.

In [38]:

```
df3=df.copy()

df3 = df3.drop('Cabin', 1)

sns.heatmap(df3.isnull(), cbar=False)

df3['Age']=df3['Age'].fillna(df3['Age'].mean())

df3=df3.dropna()
sns.heatmap(df3.isnull(), cbar=False)
print(df3.shape)
```

```
(155, 12)
```

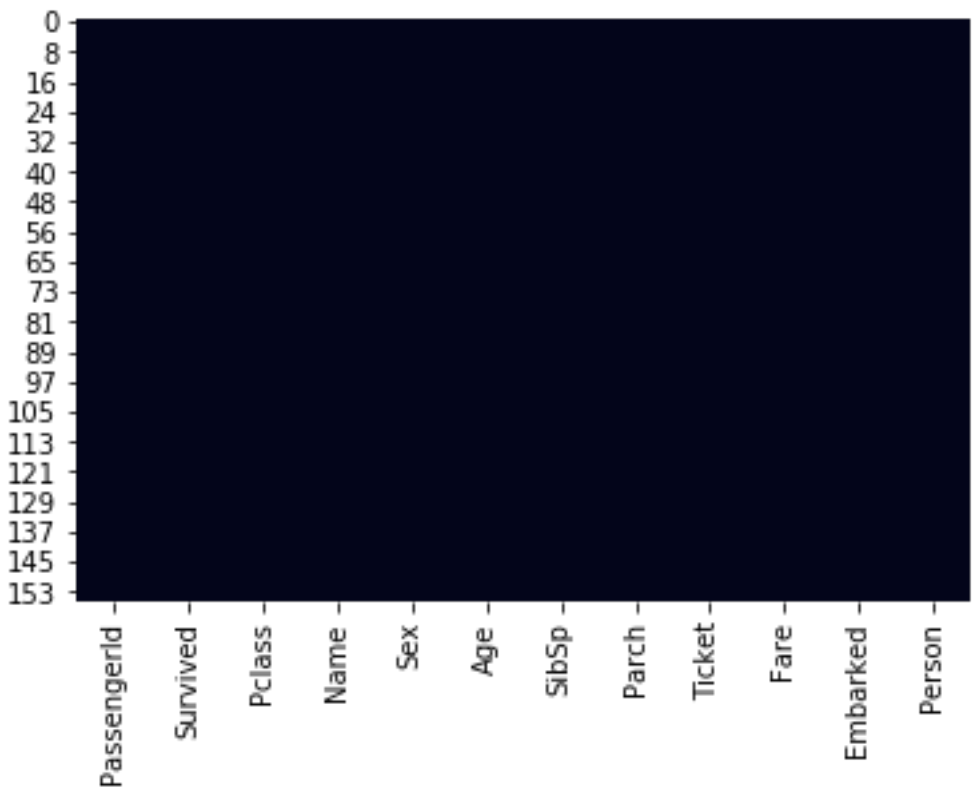

Afficher à présent l'histogramme des ages.

In [39]:

```
age_dist=sns.distplot(df3["Age"])
age_dist.set_title("Distribution des ages")
```

```
/Users/pascalponcelet/Desktop/Sicki-learn/Tools/tools/lib/python3.6/
site-packages/matplotlib/axes/_axes.py:6521: MatplotlibDeprecationWa
rning:
The 'normed' kwarg was deprecated in Matplotlib 2.1 and will be remo
ved in 3.1. Use 'density' instead.
  alternative="'density'", removal="3.1")
```

Out[39]:

```
Text(0.5, 1.0, 'Distribution des ages')
```

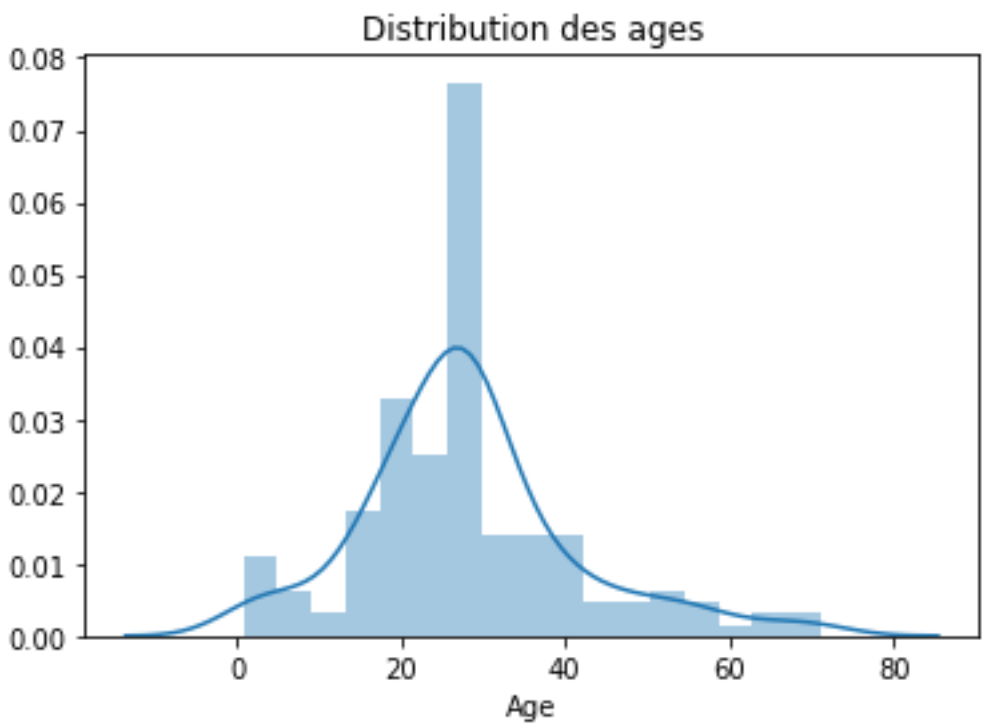

Suppression des colonnes inutiles

Dans cette étape il convient de supprimer les colonnes qui ne seront pas utiles pour la classification. La question à se poser est pour chaque colonne : est ce que cela a un sens de la conserver ?
Il faut faire des choix qui peut être auront une conséquence sur la classification !!

Dans le jeu de données nous voyons qu'il n'y a sans doute pas d'intérêt de conserver le numéro de ticket car il ne semble pas qu'il y ait un codage particulier.
Le nom des passager semble inutile. Pourtant si l'on regarde un peu attentivement (df3.display()) on peut se rendre compte qu'il existe des titres différents (Mr., Master, Miss, Rev., Mrs. etc) qui pourraient avoir un impact sur la classification.
L'identifiant du passager n'apporte pas d'information.

Effacer les différentes colonnes : 'Ticket', 'Name' et 'PassengerId'.

In [40]:

```
df3=df3.drop(['Ticket', 'Name', 'PassengerId'],
             axis=1)
```

Un petit retour sur la colonne Person.
A l'aide de display(df3.iloc[131] que constatez vous ?

In [41]:

```
1
2
3
```

```
display (df3.iloc[131])
```

```
Survived         0
Pclass           3
Sex         female
Age             47
SibSp            1
Parch            0
Fare          14.5
Embarked         S
Person       Adult
Name: 132, dtype: object
```

La fonction ayant été appliquée avant le traitement des valeurs manquantes toutes celles qui étaient manquantes ont été remplacées par le sexe de la personne. Supprimer la colonne Person.

In [42]:

```
1
```

```
df3=df3.drop(['Person'], axis=1)
```

Attributs continus

Il y a deux attributs continus dans le jeu de données. Age et Fare.

Transformer à l'aide de la fonction cut l'attribut Age de manière à ce que les valeurs puissent prendre en compte les valeurs suivantes : bins = (0, 5, 12, 18, 25, 35, 60, 120)
group_names = ['Baby', 'Child', 'Teenager', 'Student', 'Young Adult', 'Adult', 'Senior']

Transformer à l'aide de la fonction cut l'attribut Fare de manière à ce que les valeurs puissent prendre en compte les valeurs suivantes : bins = (0, 8, 15, 31, 1000)
group_names = ['1_quartile', '2_quartile', '3_quartile', '4_quartile']

In [43]:

```
bins = (0, 5, 12, 18, 25, 35, 60, 120)
#Attention le nombre de label doit être inférieur au nombre de bins
group_names = ['Baby', 'Child', 'Teenager',
               'Student', 'Young Adult',
               'Adult', 'Senior']
df3['Age']= pd.cut(df3['Age'],
                   bins, labels=group_names)



bins = (0, 8, 15, 31, 1000)
#Attention le nombre de label doit être inférieur au nombre de bins
group_names = ['1_quartile', '2_quartile',
               '3_quartile', '4_quartile']
df3['Fare']= pd.cut(df3['Fare'],
                    bins, labels=group_names)

print (df3.head())
```

```
   Survived  Pclass     Sex          Age  SibSp  Parch        Fare E
mbarked
0         0       3    male      Student      1      0  1_quartile
S
1         1       1  female        Adult      1      0  4_quartile
C
2         1       3  female  Young Adult      0      0  1_quartile
S
3         1       1  female  Young Adult      1      0  4_quartile
S
4         0       3    male  Young Adult      0      0  2_quartile
S
```

Attribut catégoriel

Pour connaître les attributs catégoriels faire un df.info(). Les attributs catégoriels apparaissent avec comme type object ou category.

In [44]:

```

print (df3.info())
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 155 entries, 0 to 155
Data columns (total 8 columns):
Survived    155 non-null int64
Pclass      155 non-null int64
Sex         155 non-null object
Age         155 non-null category
SibSp       155 non-null int64
Parch       155 non-null int64
Fare        155 non-null category
Embarked    155 non-null object
dtypes: category(2), int64(4), object(2)
memory usage: 9.3+ KB
None
```

Il y a 4 attributs catégoriels à présent dans le jeu de données. Pour chacun d'entre eux transformer les en valeur numérique à l'aide de la fonction LabelEncoder().

In [45]:

```
from sklearn.preprocessing import LabelEncoder

class_label_encoder = LabelEncoder()


# transformation
df3["Sex"]=class_label_encoder.fit_transform(df3["Sex"])
df3["Embarked"]=class_label_encoder.fit_transform(df3["Embarked"])
df3["Fare"]=class_label_encoder.fit_transform(df3["Fare"])
df3["Age"]=class_label_encoder.fit_transform(df3["Age"])
display(df3.sample(5))
```

	Survived	Pclass	Sex	Age	SibSp	Parch	Fare	Embarked
16	0	3	1	1	4	1	2	1
2	1	3	0	6	0	0	0	2
125	1	3	1	2	1	0	1	0
52	1	1	0	0	1	0	3	0
62	0	1	1	0	1	0	3	2

Remarque
En fonction des environnements, l'application de LabelEncoder, peut provoquer des erreurs.
Par exemple,
df3["Fare"]=class_label_encoder.fit_transform(df3["Fare"])
TypeError: '<' not supported between instances of 'str' and 'float'
Cela est dû au fait que comme Fare contient des caractères et des chiffres, un environnement peut le considérer comme un objet et non plus comme un str.

Pour pallier ce problème il suffit de forcer le type :
df3["Fare"] = class_label_encoder.fit_transform(df3["Fare"].astype(str))

Sauvegarde du fichier transformé

A présent sauvegarder le fichier modifié en titanic2.csv avec comme tabulateur des ';' en conservant l'entête.

In [46]:

```
import sys

print (df3.info())
print (df3.shape)
print ('\nAffichage du fichier sauvegardé avec ; comme séparateur et avec e
df3.to_csv('titanic2.csv',sep=';', index=False)


```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 155 entries, 0 to 155
Data columns (total 8 columns):
Survived    155 non-null int64
Pclass      155 non-null int64
Sex         155 non-null int64
Age         155 non-null int64
SibSp       155 non-null int64
Parch       155 non-null int64
Fare        155 non-null int64
Embarked    155 non-null int64
dtypes: int64(8)
memory usage: 10.9 KB
None
(155, 8)

Affichage du fichier sauvegardé avec ; comme séparateur et avec entê
te
```

Vérifier que votre fichier a été correctement sauvegardé.

In [47]:

```
df=pd.read_csv('titanic2.csv', sep=';')
df.head()
```

Out[47]:

	Survived	Pclass	Sex	Age	SibSp	Parch	Fare	Embarked
0	0	3	1	4	1	0	0	2
1	1	1	0	0	1	0	3	0
2	1	3	0	6	0	0	0	2
3	1	1	0	6	1	0	3	2
4	0	3	1	6	0	0	1	2